

Etapla 2. Conociendo los datos

Aplicación de métodos multivariados en ciencia de datos

Jessica Yesenia Garza Gómez – A01236941

Ilse Nahomi Paz Ramírez – A00841078

Arturo Daniel Cruz Hernández – A01750915

Gabriel Cubas Cabrera – A01833464

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Monterrey

MA2003B Grupo 201

Profesora Dra. Blanca Rosa Ruiz Hernández

Profesor Jesús Armenta Segura

8 de octubre de 2026

Índice

1. Objetivo de indagación	3
1.1. Pregunta de investigación.	3
1.2. Objetivo	3
1.3. Modificaciones respecto a la Etapa 1	3
2. Ruta de análisis propuesta	3
3. Datos y variables relevantes	4
3.1. Descripción de las variables	4
3.2. Estación de monitoreo	5
4. Exploración descriptiva orientada al objetivo	6
4.1. Relaciones entre variables	6
5. Síntesis de hallazgos descriptivos	8
5.1. Hallazgos relacionados con el objetivo	8
5.2. Limitaciones y problemas de los datos	9
5.3. Análisis pendientes y siguientes pasos	9
5.4. Nuevas preguntas	9
6. Referencias	10
A. Anexos	10
B. Reproducibilidad del análisis	10
B.1. Repositorio y archivos de trabajo	10
B.2. Declaratoria de uso de inteligencia artificial	10

1. Objetivo de indagación

1.1. Pregunta de investigación.

¿Con qué exactitud puede predecirse la concentración horaria de ozono en el Área Metropolitana de Monterrey con un horizonte de 24 horas a partir de variables meteorológicas, precursores fotoquímicos y variables de calendario, y qué tan consistente es esa capacidad predictiva entre estaciones de monitoreo?

1.2. Objetivo

Modelar la concentración horaria de ozono en las estaciones de la red SIMA del Área Metropolitana de Monterrey como función de las variables meteorológicas: temperatura, humedad relativa, radiación solar, precipitación, presión atmosférica, dirección del viento y velocidad del viento, de los precursores fotoquímicos (NO, NO₂ y CO) y de variables de tiempo, con el fin de predecir dicha concentración con un horizonte de hasta 24 horas. El modelo se ajusta sobre el periodo 2021–2026 y se evalúa mediante el coeficiente de determinación (R^2) y el error cuadrático medio (MSE), bajo una validación temporal en dos pasos: entrenamiento con 2021–2024 y validación con 2025, y posteriormente entrenamiento con 2021–2025 y prueba con 2026.

1.3. Modificaciones respecto a la Etapa 1

- **De clasificación a regresión.** El objetivo original anticipaba los días por encima de 60 ppb. Dado que R^2 y MSE son métricas de predicción de una variable continua, se replanteó como regresión sobre la concentración. La clasificación en bandas del Índice AIRE Y SALUD se conserva como objetivo específico, aplicada sobre los valores predichos.
- **Exclusión de NOx.** Equivale a la suma de NO y NO₂ en más del 99 % de los registros, por lo que su inclusión produciría una matriz de diseño mal condicionada. Se conservan NO y NO₂ por separado porque el primero consume ozono por titulación y el segundo lo produce al fotolizarse.
- **Exclusión de 2020.** Solo operaban 13 estaciones, falta el ozono en el 58.6 % de sus horas y diez combinaciones de estación y año conservan menos del 10 % de sus registros. El periodo queda en 2021–2026 (522 208 registros).
- **Validación.** Se sustituyó la partición única por el esquema en dos pasos descrito arriba.

2. Ruta de análisis propuesta

La selección de técnicas se apoya en los antecedentes revisados. Iglesias-Gonzalez et al. (2020) emplearon regresión múltiple con variables meteorológicas para pronosticar ozono en el Área Metropolitana de Monterrey, y Hernández Paniagua et al. (2017) documentaron su variabilidad entre estaciones y sectores de viento en la misma zona. Liu et al. (2025) mostraron que incorporar rezagos horarios de O₃ y NO₂ eleva el R^2 de 0.767 a 0.873, mientras que Zhang et al. (2024) advirtieron que el desempeño disminuye al validar en estaciones no vistas, lo que justifica reportar los resultados de forma desagregada. Ye et al. (2026) añaden que la importancia atribuida a cada variable meteorológica varía entre regiones y modelos.

Tabla 1: Técnicas previstas, variables implicadas y justificación.

Técnica	Variables y su función	Qué permite estudiar y por qué es adecuada
Correlaciones y descriptiva multivariada	Las 19 variables cuantitativas; O ₃ como referencia y el resto como variables a caracterizar.	Describe la estructura de asociación antes de modelar. Confirma el mecanismo fotoquímico y detecta las dependencias que condicionan los pasos siguientes.
Componentes principales	Bloque meteorológico y bloque de precursores como variables activas; O ₃ queda fuera del cálculo y sirve para interpretar los componentes.	Reduce la dimensionalidad de bloques correlacionados. Resuelve la colinealidad sin descartar información y permite interpretar los componentes en términos físicos (Iglesias-Gonzalez et al., 2020). Requiere estandarizar.
Conglomerados	Perfil medio de cada estación; la pertenencia al grupo pasa a ser variable categórica del modelo.	Agrupar las quince estaciones en un número reducido de perfiles. Las medias por estación van de 22.0 a 29.9 ppb siguiendo el gradiente topográfico del valle (Hernández Paniagua et al., 2017), y sustituye catorce variables dummy por dos o tres.
Regresión lineal múltiple	O ₃ como respuesta; meteorología, precursores, calendario en codificación circular y conglomerado como predictoras, todas rezagadas al horizonte de predicción.	Modela la relación funcional y produce la predicción. Corresponde a una respuesta continua y genera las métricas solicitadas; ya se ha empleado para pronosticar ozono en esta misma ciudad (Iglesias-Gonzalez et al., 2020) y la incorporación de rezagos mejora el ajuste (Liu et al., 2025).
Análisis discriminante	La banda del Índice AIRE Y SALUD como variable de agrupación; las predictoras del modelo como variables discriminantes.	Clasifica en las bandas de calidad del aire e identifica las variables que mejor las separan. Traduce la predicción numérica al lenguaje con que la norma comunica el riesgo.

3. Datos y variables relevantes

3.1. Descripción de las variables

Las tres variables precursoras intervienen en la química del ozono de forma distinta: el NO₂ lo produce al fotolizarse con la luz solar, mientras que el NO lo consume por titulación. El CO participa como precursor en el ciclo fotoquímico.

Tabla 2: Variables precursoras: descripción, dominio y calidad (datos medidos, 2021–2026).

Nombre	Descripción	Tipo	Unidad y rango	Datos faltantes	Valores inusuales
CO	Monóxido de carbono. Gas inorgánico tóxico procedente de la combustión incompleta de materiales orgánicos (gas de cocina, madera, carbón) cuando hay poco oxígeno. Precursor del ozono.	Cuantitativa continua	ppm; de 0 a 37; mediana de 1.12	8.65 % (18.1 % en NO3)	0.66 % atípicos
NO ₂	Dióxido de nitrógeno. Se emite en la combustión y se forma a partir del NO; con la luz solar da lugar al ozono.	Cuantitativa continua	ppb; de 0 a 167.8; mediana de 11.5	8.21 % (25.2 % en NO3)	0.89 % atípicos
NO	Monóxido de nitrógeno. Procede principalmente del tráfico y, a diferencia del NO ₂ , destruye el ozono.	Cuantitativa continua	ppb; de 0.3 a 945.1; mediana de 5	9.09 % (25.4 % en NO3)	7.89 % atípicos; picos reales de tráfico, no eliminados

3.2. Estación de monitoreo

La estación de monitoreo es una variable categórica con 15 niveles (CE, NE, NE2, NE3, NO, NO2, NO3, NTE, NTE2, SE, SE2, SE3, SO, SO2 y SUR) y no presenta valores faltantes. Se incluye porque cada zona tiene distinto tráfico, instalaciones industriales y régimen de viento, lo que modifica el comportamiento del ozono. En el análisis descriptivo se usa para comparar zonas y, en el modelo, se incorpora como variable dummy con CE como referencia.




Figura 1: Número de registros disponibles por estación de monitoreo, 2021–julio 2026.

La Figura 1 muestra el número de registros por estación. Ninguna alcanza las 48 912 horas posibles del periodo, y la diferencia entre ellas es considerable: NTE2 reúne 45 272 registros frente a los 15 564 de NO3, una razón de 2.9 a uno. Siete estaciones superan el 80 % de cobertura; NTE y NO3 no llegan al 40 %, la primera por pérdida progresiva de registro hasta 2025 y la segunda porque inicia operaciones a finales de 2022. Como la pregunta de investigación indaga qué tan consistente

es la capacidad predictiva entre estaciones, el desempeño del modelo se reportará desagregado por estación y por año: una medida global ocultaría que las estaciones con menos observaciones aportan menos información al entrenamiento.

4. Exploración descriptiva orientada al objetivo

4.1. Relaciones entre variables




Figura 2: Correlación lineal de cada variable con la concentración de ozono.

La Figura 2 confirma el mecanismo fotoquímico documentado en la literatura: la radiación solar y la temperatura favorecen la formación de ozono, mientras que la humedad relativa la inhibe. Los precursores aparecen con signo negativo, congruente con la titulación del ozono por óxido nítrico, y la meteorología los supera en magnitud. El ciclo diario resulta determinante y deberá modelarse explícitamente. En contraste, el CO y la precipitación muestran asociación lineal prácticamente nula; en RAINF esto refuerza la necesidad de verificar la conversión de unidades documentada por SIMA. Conviene notar que se trata de correlaciones lineales y que la relación del ozono con la hora no es monótona, sino que alcanza su máximo al mediodía, por lo que los coeficientes subestiman la dependencia real.




Figura 3: Distribución de la concentración de ozono por estación de monitoreo.

El ozono alcanza su máximo a media tarde y su mínimo a primera hora de la mañana, cuando el NO lo consume y aún no hay radiación suficiente para su formación. El promedio mensual es mayor en primavera y menor en invierno. La diferencia entre días hábiles y fines de semana es pequeña, por lo que el tipo de día no será una predictora prioritaria.




Figura 4: Autocorrelación de la concentración de ozono por estación, rezagos de 0 a 72 horas. Las líneas verticales marcan los múltiplos de 24 horas.

La Figura 4 muestra un patrón ondulatorio consistente en las quince estaciones: la autocorrelación cae hasta un mínimo negativo cerca del rezago 12 —el extremo opuesto del ciclo diario— y repunta en los múltiplos de 24 horas, con valores en torno a $[X]$ en el rezago 24 que decrecen en 48 y 72.

Esto confirma que el ozono de una hora guarda relación con el de la misma hora del día anterior, de modo que el horizonte de 24 horas es predecible. También fija una línea base exigente: un modelo que simplemente repitiera el valor de ayer a esta hora ya acertaría de forma apreciable, y el modelo propuesto deberá superarla incorporando meteorología, precursores y calendario.

5. Síntesis de hallazgos descriptivos

Con base en la pregunta de investigación, que indaga con qué exactitud puede predecirse el ozono horario a 24 horas y qué tan consistente es esa capacidad entre estaciones, la exploración permitió identificar tanto las condiciones que favorecen el modelado como las restricciones que deberán controlarse. A continuación se resumen los hallazgos, las limitaciones, el trabajo pendiente y las preguntas que surgieron.

5.1. Hallazgos relacionados con el objetivo

- **Cobertura desigual entre estaciones.** Ninguna de las quince estaciones completa las 48 912 horas posibles del periodo. NTE2 reúne 45 272 registros (92.6 %) y NO3 solo 15 564 (31.8 %), una razón de 2.9 a uno. Siete estaciones superan el 80 % de cobertura (Figura 1). Esto es directamente relevante para el objetivo, pues la consistencia entre estaciones podría reflejar diferencias de información disponible y no solo diferencias físicas.
- **Diferencias entre estaciones.** Las medias de ozono por estación van de 22.0 a 29.9 ppb y siguen el gradiente topográfico del valle. Las medianas se mantienen en un rango estrecho y la diferencia relevante está en la cola superior, con un máximo de 265 ppb en SE2 (Figura 3). Esto respalda agrupar las estaciones en perfiles en lugar de usar catorce variables dummy, y obliga a evaluar el desempeño también en los episodios de ozono alto.
- **Papel diferenciado de los precursores.** El NO₂ produce ozono al fotolizarse, mientras que el NO lo consume por titulación. Se conservan ambos por separado y se excluye NO_x, que equivale a su suma en más del 99 % de los registros.
- **Asociaciones entre variables.** La radiación solar ($r = 0.527$) y la temperatura ($r = 0.485$) se asocian positivamente con el ozono, y la humedad relativa de forma negativa ($r = -0.558$) (Figura 2), como corresponde a un contaminante secundario que se forma con calor y luz. Los precursores tienen signo negativo (NO, -0.294 ; NO₂, -0.257), congruente con la titulación por óxido nítrico, mientras que el CO (-0.060) y la precipitación (-0.007) muestran una asociación lineal casi nula. La hora (`hora_sin`, -0.489) también es determinante y deberá modelarse explícitamente.
- **Patrones temporales.** El ozono sigue un ciclo diario marcado, con un mínimo cercano a 11 ppb hacia las 7 h y un máximo de unos 50 ppb entre las 14 y las 15 h. El promedio mensual alcanza su máximo en mayo (aprox. 33 ppb) y su mínimo en diciembre (aprox. 20 ppb), con un repunte secundario en septiembre. Entre días hábiles y fines de semana las curvas son casi idénticas, con diferencias de 1 a 3 ppb en la mañana y la noche. Por ello la hora y el mes serán predictoras relevantes, mientras que el tipo de día aportará poco.

5.2. Limitaciones y problemas de los datos

- **Datos faltantes.** Los precursores presentan entre 8.21 % y 9.09 % de faltantes en el conjunto completo (CO 8.65 %, NO₂ 8.21 %, NO 9.09 %), y entre 18.1 % y 25.4 % en NO₃ (Tabla 2).
- **Estaciones con registro incompleto.** NTE y NO₃ no llegan al 40 % de cobertura: NTE por pérdida progresiva de registro hasta 2025 y NO₃ porque inicia operaciones a finales de 2022. Las estaciones con menos observaciones aportan menos información al entrenamiento.
- **Valores atípicos.** El NO tiene 7.89 % de atípicos, que corresponden a picos reales de tráfico y no se eliminaron; el CO y el NO₂ tienen 0.66 % y 0.89 %. Estos valores pueden influir en una regresión lineal y deberán evaluarse con medidas robustas o transformaciones.
- **Colinealidad.** Las variables meteorológicas y los precursores están correlacionados entre sí, y NO_x es redundante, lo que condiciona la estimación de coeficientes en el modelo lineal.
- **Periodo de análisis.** Se excluyó 2020 por tener solo 13 estaciones y 58.6 % de ozono faltante, por lo que el periodo analizado (2021–2026, 522 208 registros) no incluye la evolución anterior. Además, 2026 llega solo hasta julio, por lo que la prueba final no cubre un año completo ni el mismo ciclo estacional.

5.3. Análisis pendientes y siguientes pasos

El equipo seguirá la ruta de la Tabla 1 en el siguiente orden:

1. Definir el tratamiento de los datos faltantes (por ejemplo, eliminar casos incompletos o imputar) y verificarlo por estación.
2. Calcular la matriz de correlaciones de las 19 variables y aplicar componentes principales, estandarizando, a los bloques meteorológico y de precursores.
3. Agrupar las estaciones por su perfil medio y validar los grupos con MANOVA antes de incorporarlos como variable categórica.
4. Ajustar la regresión lineal múltiple con predictoras rezagadas 24 horas, calendario en codificación circular y conglomerado, con selección hacia adelante y hacia atrás.
5. Evaluar con R^2 y MSE bajo la validación en dos pasos (entrenamiento 2021–2024 con validación en 2025; entrenamiento 2021–2025 con prueba en 2026), desagregando por estación y por año.
6. Aplicar el análisis discriminante a las bandas del Índice AIRE Y SALUD para traducir la predicción al lenguaje de la norma.

5.4. Nuevas preguntas

- ¿El desempeño del modelo es menor en las estaciones con poca cobertura (NTE y NO₃), o depende más de su ubicación en el valle?
- ¿Los faltantes de NO₃, NTE y de los precursores siguen un patrón (horas, meses, fallas de equipo) o son aleatorios?
- ¿Una relación lineal es suficiente, dado que el ozono depende de interacciones entre radiación, NO y NO₂, o se requerirán términos de interacción o modelos no lineales?

- ¿Los picos de NO, que se conservaron por ser reales, afectan la estabilidad de los coeficientes?
- ¿Cambia la relación entre meteorología y ozono entre 2021 y 2026, de modo que un modelo entrenado en años previos pierda exactitud en 2026?

6. Referencias

- Hernández Paniagua, I. Y., Clemitshaw, K. C., & Mendoza, A. (2017). Observed trends in ground-level O₃ in Monterrey, Mexico, during 1993–2014: comparison with Mexico City and Guadalajara. *Atmospheric Chemistry and Physics*, *17*, 9163–9175. <https://doi.org/10.5194/acp-17-9163-2017>
- Iglesias-Gonzalez, S., Huertas-Bolanos, M. E., Hernandez-Paniagua, I. Y., & Mendoza, A. (2020). Explicit Modeling of Meteorological Explanatory Variables in Short-Term Forecasting of Maximum Ozone Concentrations via a Multiple Regression Time Series Framework. *Atmosphere*, *11*(12), 1304. <https://doi.org/10.3390/atmos11121304>
- Liu, Z., Lu, Z., Zhu, W., Yuan, J., Cao, Z., Cao, T., Liu, S., Xu, Y., & Zhang, X. (2025). Comparison of machine learning methods for predicting ground-level ozone pollution in Beijing. *Frontiers in Environmental Science*, *13*. <https://doi.org/10.3389/fenvs.2025.1561794>
- Ye, X., Zhang, L., Wang, X., Lu, N., Hickman, S., Luo, G., & Archibald, A. T. (2026). Deciphering the impacts of meteorology on surface ozone variability in eastern China using explainable machine learning models. *Atmospheric Chemistry and Physics*, *26*, 6377–6390. <https://doi.org/10.5194/acp-26-6377-2026>
- Zhang, W., Liu, D., Tian, H., Pan, N., Yang, R., Tang, W., Yang, J., Lu, F., Dayananda, B., Mei, H., Wang, S., & Shi, H. (2024). Parsimonious estimation of hourly surface ozone concentration across China during 2015–2020. *Scientific Data*, *11*, 492. <https://doi.org/10.1038/s41597-024-03302-3>

A. Anexos

B. Reproducibilidad del análisis

B.1. Repositorio y archivos de trabajo

El código desarrollado y la base de datos limpia están disponibles en <https://github.com/a01236941/Reto-Multi-Equipo4>. La carpeta `data/final` contiene la base utilizada en este análisis; `R/` y `python/` contienen los scripts de limpieza, imputación y exploración, y `reports/` los archivos de auditoría y el diccionario de criterios.

B.2. Declaratoria de uso de inteligencia artificial

Opción B. Se utilizó IA de la siguiente forma.

Herramienta: Prism y ChatGPT de OpenAI.

Uso realizado: Se utilizó para dar formato al documento (estructura en $\text{\LaTeX}$, tablas y bibliografía) y para ayudar a encontrar fuentes e información relevante sobre calidad del aire, ozono y métodos de imputación y predicción.

Secciones donde se utilizó: Revisión bibliográfica, marco normativo, comprensión y preparación de los datos, así como el formato general del documento, sus tablas y su bibliografía.

Validación realizada por los estudiantes: Las fuentes principales fueron revisadas manualmente por el equipo, verificando que existiera, que correspondiera a lo citado y que las cifras reportadas coincidieran con el original. Los análisis y las cifras de la preparación de datos se obtuvieron de la base de datos y se contrastaron con los archivos de auditoría del repositorio. Los estudiantes confirmamos que revisamos y verificamos el contenido y asumimos la responsabilidad del trabajo final entregado.