Etapa 3. Adecuación y/o validación del Modelo

Aplicación de métodos multivariados en ciencia de datos

Jessica Yesenia Garza Gómez – A01236941

Ilse Nahomi Paz Ramírez – A00841078

Arturo Daniel Cruz Hernández – A01750915

Gabriel Cubas Cabrera – A01833464

Equipo 4

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Monterrey

MA2003B Grupo 201

Profesora Dra. Blanca Rosa Ruiz Hernández

Profesor Jesús Armenta Segura

15 de octubre de 2026

Introducción

La calidad del aire en el Área Metropolitana de Monterrey está condicionada por la combinación de emisiones debido al tráfico, emisiones industriales y la topografía del valle que sirve como centro de cocción de contaminantes. Entre ellos vamos a destacar uno de los contaminantes más perjudiciales para el ser humano, el ozono troposférico (O_3), con la peculiaridad de que este no se emite directamente sino que se forma en la atmosférica a partir de precursores como los óxidos de nitrógeno, en presencia de radiación solar y temperaturas altas. Por ello su concentración depende tanto de emisiones como de las condiciones meteorológicas.

Este análisis forma parte del reto que nos propuso SIMA y sigue la metodología CRISP-DM. Primero definimos el problema en la primera etapa así como el objetivo de indagación en la primera etapa, en la segunda se integraron, limpiaron y exploraron los datos horarios de la red de monitoreo imputando los huecos cortos de las variables predictoras con SAITS, construyendo una base de modelado e identificando las relaciones principales entre el ozono, la meteorología y los precursores. En esta etapa, partiremos de esos resultados para ajustar el objetivo a los datos disponibles y avanzar hacia la modelación.

Objetivo del análisis

Objetivo inicial y cambios

Modelar la concentración horaria del ozono en las estaciones de la red SIMA del Área Metropolitana de Monterrey como función de las variables meteorológicas (temperatura, humedad relativa, radiación solar, presión atmosférica, dirección y velocidad del viento), de los precursores fotoquímicos (NO, (NO_2) y CO) y de variables de tiempo, con el fin de predecir dicha concentración con un horizonte de hasta 24 horas. El modelo se ajusta sobre el periodo 2021-2026 y se evalúa mediante R^2 y MSE bajo una validación temporal en dos pasos: entrenamiento con 2021–2024 y validación con 2025, y posteriormente entrenamiento con 2021–2025 y prueba con 2026.

Excluimos las estaciones NO3 (NO3, García) y NTE (NTE, General Escobedo) por su

falta de datos ya que en ambas se registraron menos del 40% de horas posibles del periodo. Por otra parte eliminamos la variable meteorológica RAINF ya que, aunque pueda parecer relevante, solo representan el 1.7% de las horas registradas y su efecto se ve reflejado en la humedad relativa y la radiación solar.

Objetivo actualizado

Modelar la concentración horaria de ozono en el Área Metropolitana de Monterrey, a partir de las 13 estaciones de la red SIMA con cobertura suficiente en el periodo 2021–2026, como función de las variables meteorológicas (temperatura, humedad relativa, radiación solar, presión atmosférica, dirección y velocidad del viento), de los precursores fotoquímicos (NO, (NO_2) y CO) y de variables de calendario, con el fin de predecir dicha concentración con un horizonte de hasta 24 horas y evaluar qué tan consistente es esa capacidad predictiva entre las estaciones analizadas. El desempeño se medirá mediante el coeficiente de determinación (R^2) y el error cuadrático medio (MSE), bajo una validación temporal en dos pasos: entrenamiento con 2021–2024 y validación con 2025, y entrenamiento con 2021–2025 y prueba con 2026.

Datos preparados para el modelado

La base de modelado proviene del preprocesamiento de las mediciones horarias de SIMA. Contiene 488 029 registros de 13 estaciones del Área Metropolitana de Monterrey, de enero de 2021 a julio de 2026. Se excluyeron las estaciones NTE y NO3 por cobertura inferior al 40 % del periodo, y el año 2020 por la proporción de ozono no medido en sus horas(58.6%). Cada registro corresponde a una estación y una hora.

La variable respuesta es la concentración de ozono 24 horas después del momento de pronóstico. Las predictoras son: el ozono en el momento de origen (como rezago diario del objetivo), temperatura (TOUT, °C), humedad relativa(RH, %), radiación solar (SR, kW/m^2), presión atmosférica (PRS,mmHg, sin transformar), velocidad del viento (WSR, km/h), dirección del viento (transformada como desviación angular respecto al pico de ozono de cada estación), monóxido de carbono (CO, ppm), monóxido de nitrógeno (NO, ppb), dióxido de nitrógeno (NO_2,

ppb), y la hora y el mes del momento objetivo como variables categóricas, y la estación como efecto fijo. Para el modelo transformado se agregan rezagos de 1 a 3 horas de O_3 y NO_2. La precipitación (RAINF) y el óxido de nitrógeno total (NOx) no se incluyen: la primera porque en la base presenta una asociación lineal prácticamente nula con la concentración de ozono ($r = -0.008$) y registra valores positivos en menos del 1.5 % de las horas, por lo que su aporte potencial al modelo es marginal; y el segundo por ser prácticamente la suma de NO y NO_2.

La preparación incluyó la imputación de huecos de hasta 24 horas mediante SAITS, un modelo Transformer de autoatención; los huecos más largos se conservaron como faltantes. Las filas sin ozono medido se excluyeron, porque la respuesta no puede ser un valor imputado. Las filas con alguna predictora faltante también se excluyeron, de modo que todos los modelos se ajustan y evalúan sobre la misma muestra. Las transformaciones se aplicaron únicamente con información de la hora de origen: el logaritmo de la temperatura, los polinomios de humedad y radiación, la inversa del viento y la desviación de la dirección respecto de la dirección pico de ozono de cada estación, estimada con datos de entrenamiento.

La partición fue temporal. El primer paso entrena con 2021 a 2024 y valida con 2025; el segundo entrena con 2021 a 2025 y prueba con 2026, que solo cubre enero a julio.

Métodos estadísticos

Se utilizaron dos técnicas estadísticas, una de dependencia para predecir el ozono y otra de interdependencia para identificar regímenes de condiciones, junto con un Análisis de Componentes Principales para reducir dimensionalidad

Técnica 1: Regresión lineal múltiple

Tipo: Dependencia.

Variables y propósito: Usando una transformación logarítmica para la variable objetivo del ozono, se busca predecir el logaritmo del ozono 24 horas después de la hora de origen en las 13 estaciones. Siguiendo la metodología de Iglesias Gonzales et al. (2020), se ajustó una regresión lineal múltiple sobre la transformación del ozono a ln(O3), así como las transformaciones

de variables adicionales como el ln(temperatura ln(temperatura + 273.15), polinomio de grado 3 para la humedad relativa, de grado 2 para la radiación solar, 1/(velocidad del viento + 1), y la desviación angular de la dirección del viento respecto al ángulo donde ocurre el pico de ozono en cada estación. También se incluyeron efectos de hora y mes, un efecto fijo por estación, la presión sin transformar, NO, NO, y CO. Siguiendo a Liu et al. (2025), se agregaron el ozono en el momento de origen y los rezagos de 1 a 3 horas de O, y NO.La hora y el mes se tomaron de la hora objetivo, y la partición entre entrenamiento y prueba se hizo por año objetivo para evitar fuga de información.

Justificación: Esta técnica estadística aporta al objetivo de investigación ya que ayuda a predecir los niveles de ozono con un modelo interpretable.En cuanto a las transformaciones realizadas, el logaritmo corrige la asimetría y mantiene positivas las predicciones, que se devuelven a ppb con el factor de smearing (1.1327), el cual no supone normalidad de los errores.

Supuestos:

Supuesto	**Evaluación**
Linealidad	Se revisó con residuos contra valores ajustados, tras las transformaciones.
Homocedasticidad	No se cumple. La dispersión del residuo en escala log baja de 0.726 en el primer decil del ajuste a 0.349 en el décimo, y la prueba de Breusch-Pagan la rechaza. Afecta la inferencia, no la predicción puntual.
Normalidad	No se cumple. La asimetría es -0.56 y la curtosis 4.98 (colas pesadas); el smearing evita que esto sesgue la retrans formación (Figura 3 en Anexos).
Independencia	No se cumple en rezagos cortos (ACF de 0.859, 0.670 y 0.503 en los rezagos 1, 2 y 3) y es casi nula en los rezagos 12, 24 y 48 (-0.010, -0.027, 0.075). Por ello, los p-valores resultan optimistas y la importancia de las variables se interpreta como ranking descriptivo.

Tabla 1
Evaluación de los supuestos del modelo.

Técnica 2: PCA y K-means

Tipo: Interdependencia.

Variables y propósito: Se usan diez condiciones: temperatura, humedad relativa, radiación, velocidad y componentes de dirección del viento, presión, y NO, NO_2 y CO en $\log(1 + x)$.Cada variable se centra por estación y se estandariza.

Justificación: Esta técnica de interdependencia responde la pregunta de investigación referente a encontrar régimenes de condiciones meteorológicas. Se agrupan días y no estaciones porque con solo 13 estaciones el k-means es inestable, mientras que los más de 16 mil días dan una estructura estable. Los componentes principales se aplican antes del k-means para decorrelacionar las variables y reducir ruido

Supuestos:

- *Correlación suficiente para resumir:* la prueba de Bartlett rechaza que la matriz sea identidad ($\chi^2 = 41{,}588$, 45 gl) y el KMO global es 0.678. Las correlaciones son moderadas (mediana de $|r|$ de 0.15; máximo 0.67 entre NO y NO_2), por lo que el resumen es modesto: seis componentes explican 83.5 % de la varianza.

- *Escalas comparables y asimetría:* se estandarizó y se aplicó $\log(1 + x)$ a NO, NO_2 y CO.

- *Forma de los grupos y sensibilidad del k-means:* se eligió $k = 3$ con codo, silueta y estabilidad(Figura 4 en Anexos). Los grupos con $k = 3$ y $k = 4$ son estables (ARI = 0.996); desde $k = 5$ dejan de ser reproducibles (ARI de 0.45 a 0.60). La silueta es baja (0.227 con $k = 3$).

- *Sin fuga de información:* el agrupamiento se ajusta solo con 2021–2024 y los días de 2025 y 2026 se asignan al centroide más cercano.

Procedimiento de validación

La regresión se validó con particiones temporales por año objetivo, para evitar fuga de información: entrenamiento con 2021 a 2024 y validación en 2025, y entrenamiento con 2021 a 2025 y prueba en 2026 (enero a julio,debido a que fue el último mes capturado en la base de datos). Las métricas, calculadas en ppb tras el smearing, son MAE, RMSE, MSE, R^2 y sesgo,

globalmente y por estación. Además se calcula el AUC para episodios con $O_3 > 70$ ppb y la proporción de episodios detectados con una alerta a ese mismo umbral, definido antes de ver los resultados basado en la información proporcionada por SIMA. Se clasifica cada hora como acierto, falsa alarma o peligro no detectado. Los errores también se reportan por grupo de k-means. Como análisis de sensibilidad se reajustó el modelo sin las 82 lecturas de NO por encima de 300 ppb. El k-means se evalúa con métodos de codo, silueta y estabilidad entre semillas.

Resultados

Evaluación y comparación de modelos

El modelo explica cerca del 60 % de la variabilidad del ozono horario a 24 horas, con un desempeño estable entre 2025 ($R^2 = 0.622$, RMSE de 12.9 ppb) y 2026 ($R^2 = 0.587$, RMSE de 12.7 ppb). El sesgo es pequeño y negativo (-0.87 y -0.46 ppb), por lo que se podría decir que el modelo tiende a subestimar. La capacidad predictiva es consistente entre estaciones, con R^2 entre 0.51 y 0.67 en 2025 y entre 0.43 y 0.63 en 2026. Varias estaciones tienen lagunas largas de datos, por ejemplo NE y SO, por lo que sus cifras se apoyan en menos información y en épocas distintas del año. El análisis de sensibilidad no cambia esta lectura: al excluir las 82 lecturas de NO mayores de 300 ppb, el RMSE (12.85 ppb) y el R^2 (0.623) de 2025 son prácticamente idénticos.

Como clasificador de picos el modelo ordena bien las horas por riesgo (AUC de 0.931 y 0.938), pero con un umbral de alerta de 70 ppb detecta solo 21 % de los episodios en 2025 y 25 % en 2026. En 2025, de 69,618 horas evaluadas, 2,747 son peligro no detectado y 872 son falsa alarma. Casi todo el error crítico son picos que superan apenas el umbral, el modelo sirve para ordenar riesgo, pero todavía no como sistema de alerta.

La Figura 1 muestra, para la estación SO2,la de mayor número de episodios en 2025, dónde el modelo no detecta picos (rojo, 443 horas) o emite falsas alarmas (amarillo, 143 horas); casi todo el rojo son picos que superan apenas los 70 ppb. Para ver las demás estaciones,es la Figura 5 en Anexos.

Los tres regímenes de días son: el grupo 1 es fresco y húmedo (16.5 °C, 68 % de humedad), con poca radiación y concentrado de noviembre a febrero; el grupo 2 es templado y seco (22 °C,

Figura 1

Errores de predicción de O_3 en la estación SO2 en 2025: sin error crítico (gris), falsa alarma (amarillo) y peligro no detectado (rojo), con umbral de 70 ppb.

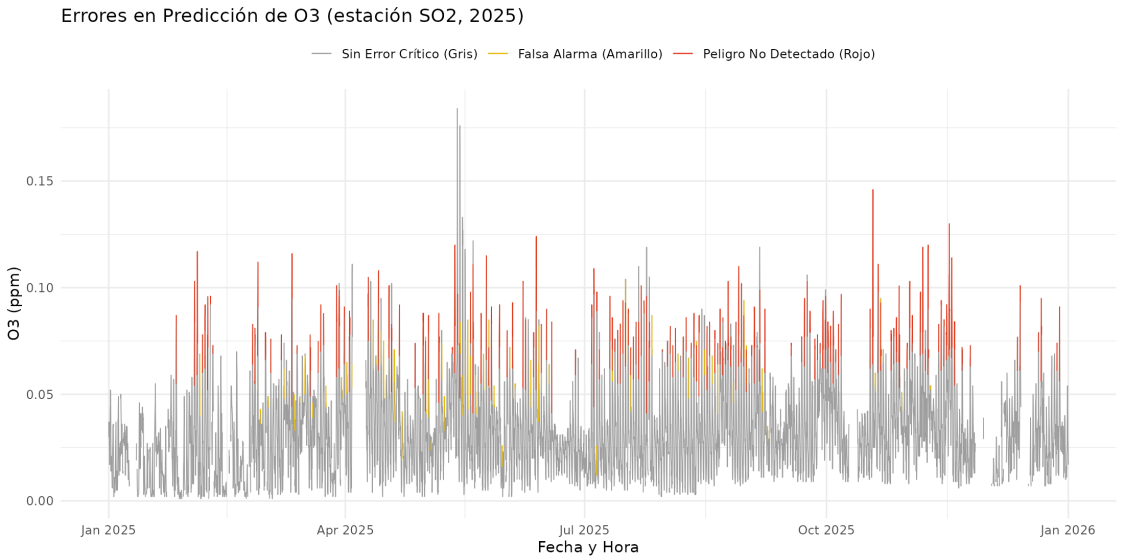


Tabla 2

Desempeño de los modelos

Modelo	Validación	Métrica(s)	Resultado(s)
Regresión lineal múltiple (modelo D)	Entrenamiento 2021–2024, validación 2025	R^2; RMSE (ppb); MAE (ppb); sesgo (ppb); AUC	0.622; 12.87; 9.25; -0.87; 0.931
Regresión lineal múltiple (modelo D)	Entrenamiento 2021–2025, prueba 2026 (ene–jul)	R^2; RMSE (ppb); MAE (ppb); sesgo (ppb); AUC	0.587; 12.72; 9.21; -0.46; 0.938
Componentes principales y k-means ($k = 3$)	Entrenamiento 2021–2024; estabilidad entre semillas	Silueta; ARI	0.227; 0.996

48 %), con los precursores más altos (NO de 16, NO_2 de 21 y CO de 1.54), de octubre a marzo; el grupo 3 (10,685 días) es cálido (27 °C) y con mucho viento, con pocos precursores, de abril a octubre, como se puede ver en la siguiente figura.

Figura 2

Días de entrenamiento en el plano de los dos primeros componentes, coloreados por grupo de k-means.

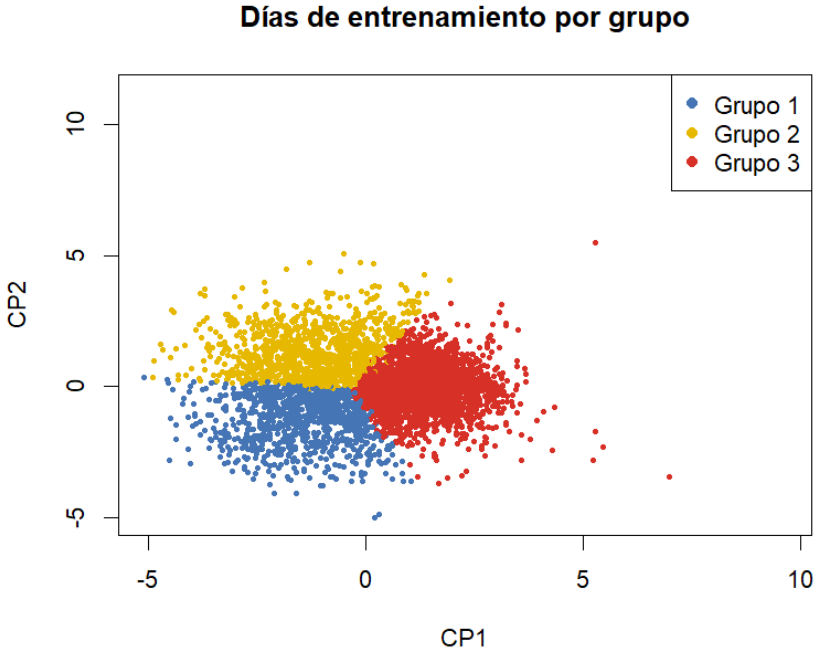


Tabla 3

Error del modelo por grupo de k-means (2025 / 2026 ene–jul)

Grupo	RMSE (ppb)	R^2 (2025)	Episodios detectados (%)
1: fresco y húmedo	12.0 / 12.6	0.55	1.0 / 0.0
2: seco, precursores altos	15.9 / 15.0	0.58	26.7 / 26.0
3: cálido y ventoso	11.7 / 11.7	0.65	20.5 / 31.2

El modelo falla más en el grupo 2: es donde el RMSE es más alto en ambos años y donde la proporción de horas con episodios es mayor (7.9 % en 2025, contra 2.1 % y 4.9 %). El grupo 3 es donde mejor ajusta (R^2 de 0.65), pero concentra más episodios perdidos en número (1,496 en 2025) porque reúne más de la mitad de las horas. En el grupo 1 casi no ocurren episodios, por lo

que su baja detección pesa poco.

Conclusión parcial y siguientes pasos

En esta etapa se ajustó una regresión lineal múltiple sobre $\ln(O_3)$ con el objetivo de predecir el ozono horario a 24 horas en las 13 estaciones de la red SIMA con cobertura suficiente, y al mismo tiempo se aplicaron PCA y k-means a fin de identificar regímenes de condiciones. El modelo explica cerca del 60% de la variabilidad del ozono y mantiene un desempeño estable, ya que obtuvo $R^2 = 0.622$ y RMSE = 12.87 ppb en la validación de 2025, así como $R^2 = 0.587$ y RMSE = 12.72 ppb en la prueba de 2026 de enero a julio, aunque su sesgo es pequeño y negativo (-0.87 y -0.46 ppb), de manera que existe una ligera tendencia a subestimar.

Asimismo, la capacidad predictiva es consistente entre estaciones, con R^2 de 0.51 a 0.67 en 2025 y de 0.43 a 0.63 en 2026, y el análisis de sensibilidad sin las 82 lecturas de NO mayores a 300 ppb no modificó los resultados ($R^2 = 0.623$ y RMSE = 12.85 ppb). Por otro lado, el agrupamiento con $k = 3$ resultó estable (ARI = 0.996) y distingue tres regímenes de días, a saber, uno fresco y húmedo de noviembre a febrero, otro seco y con precursores altos de octubre a marzo, y uno cálido y ventoso de abril a octubre. El modelo se equivoca más en el segundo régimen, donde el RMSE llega a 15.9 y 15.0 ppb y además los episodios de ozono son más frecuentes, mientras que su mejor ajuste ocurre en el tercero, con $R^2 = 0.65$.

En cuanto al objetivo actualizado, los resultados lo responden en buena medida, pues se obtuvo un modelo interpretable, con desempeño consistente entre estaciones y años y validado temporalmente sin fuga de información, y de igual forma los regímenes permiten ubicar cuándo y en qué condiciones el error es mayor. Sin embargo, la respuesta es solo parcial en la detección de picos, ya que el modelo ordena bien el riesgo (AUC de 0.931 y 0.938), pero con un umbral de 70 ppb detecta únicamente 21% de los episodios en 2025 y 25% en 2026. De hecho, en 2025 se registraron 2,747 horas de peligro no detectado frente a 872 falsas alarmas, y casi todo el error crítico corresponde a picos que apenas superan el umbral, por lo tanto el modelo sirve actualmente para jerarquizar el riesgo, aunque todavía no como sistema de alerta.

El trabajo tiene limitaciones importantes, pues no se cumplen los supuestos de homo-

cedasticidad, normalidad ni independencia (por ejemplo, la autocorrelación en el rezago 1 es de 0.859), lo cual afecta la inferencia pero no la predicción puntual, de ahí que los p-valores sean optimistas y la importancia de las variables se interprete como un ranking descriptivo. Además, la regresión lineal tiende a suavizar los valores extremos, lo que explica en parte la baja detección de picos, y a esto se suma que estaciones como NE y SO presentan lagunas largas de datos, que 2026 solo cubre hasta julio y que NO3 y NTE se excluyeron por tener menos del 40% de cobertura. Por último, los grupos de k-means representan regímenes sobre un continuo y no categorías naturales, como lo indican la silueta baja (0.227) y el KMO de 0.678.

A continuación, el camino a seguir consiste primero en mejorar la detección de episodios mediante modelos que capturen no linealidades y valores extremos, como la regresión cuantílica o los árboles potenciados, y compararlos con la regresión actual bajo las mismas particiones temporales. Luego se calibrará el umbral de alerta para equilibrar los peligros no detectados y las falsas alarmas, y se evaluará si incorporar el régimen de k-means como variable, o ajustar modelos por régimen, reduce el error en el grupo 2. También se corregirá la autocorrelación con errores robustos o bloques temporales con el propósito de fortalecer la inferencia, y después se desarrollará la interfaz gráfica que permita usar el modelo y validar sus resultados, de modo que, cuando se disponga de los meses restantes de 2026, se puedan actualizar las evaluaciones.

Finalmente, con base en lo anterior surgen varias preguntas: ¿cuánto mejora la detección de picos con un modelo no lineal y a qué costo en interpretabilidad?, ¿qué umbral de alerta resulta más útil para SIMA según el costo relativo de una falsa alarma y de un peligro no detectado?, ¿qué variables o procesos, como la capa de mezcla o el transporte regional, explican la dificultad del régimen 2? y, por último, ¿se mantiene el desempeño si se cambia el horizonte de predicción a 1, 6 o 12 horas?

Acceso al código

[Pegar la liga con acceso al código del trabajo:]

[Ligaalrepositoriooarchivocompartido]

Declaratoria de uso de inteligencia artificial

Opción B. Se utilizó IA de la siguiente forma:

Herramienta: ChatGPT.

Uso realizado: Elaboración inicial del esqueleto y organización de las secciones del reporte.

Secciones donde se utilizó: Estructura general y textos guía para completar el reporte.

Validación realizada por los estudiantes: [Describir la revisión y verificación efectivamente realizadas. El equipo debe confirmar que revisó y verificó el contenido final y que asume la responsabilidad de este.]

Otro (especifique): [Indicar si corresponde o escribir “No aplica”.]

Referencias

[Incluir únicamente las fuentes citadas en el reporte y darles formato APA 7.]

Anexos

Figura 3

Diagnóstico de residuos del modelo (escala logarítmica): residuos contra valores ajustados y gráfico Q-Q.

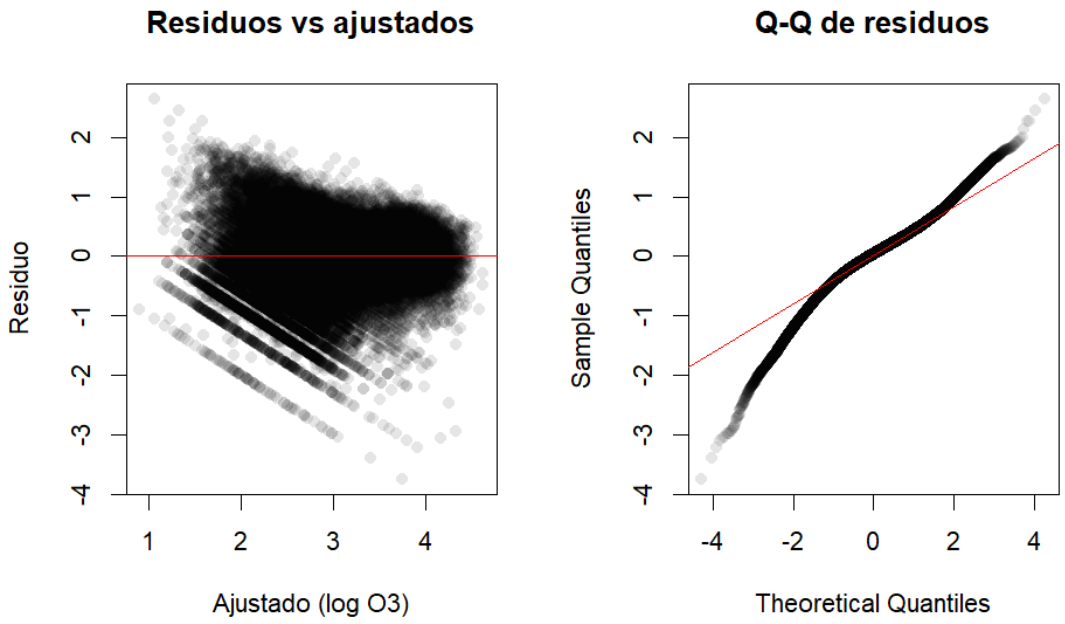


Figura 4

Elección de k: codo, silueta promedio y estabilidad.

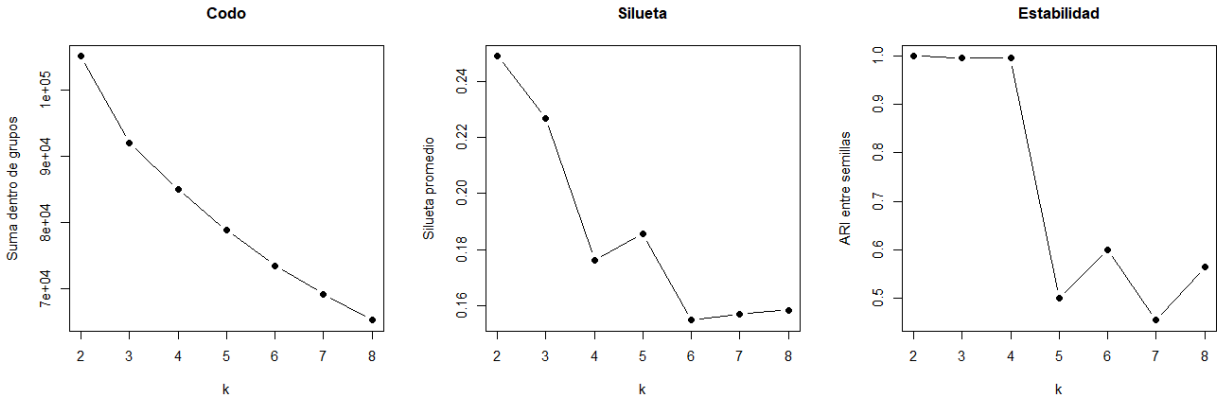


Figura 5

Errores de predicción de O_3 en 2025 por estación: sin error crítico (gris), falsa alarma (amarillo) y peligro no detectado (rojo), con umbral de 70 ppb (línea punteada). El título de cada panel indica las horas de peligro no detectado y de falsa alarma.

