Etapa 4. Informe final del Reto

Aplicación de métodos multivariados en ciencia de datos

Pronóstico de ozono a 24 horas en el Área Metropolitana de Monterrey con datos de SIMA

Jessica Yesenia Garza Gómez – A01236941

Ilse Nahomi Paz Ramírez – A00841078

Arturo Daniel Cruz Hernández – A01750915

Gabriel Cubas Cabrera – A01833464

Equipo 4

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Monterrey

MA2003B, Grupo 201

Profesora Dra. Blanca Rosa Ruiz Hernández

Profesor Jesús Armenta Segura

24 de octubre del 2026

Resumen

La calidad del aire en el Área Metropolitana de Monterrey depende de las emisiones por tráfico e industria y de la topografía del valle. El ozono troposférico (O_3) no se emite directamente: se forma a partir de precursores como los óxidos de nitrógeno bajo radiación solar y temperaturas altas. Este trabajo, desarrollado para el reto de SIMA con la metodología CRISP-DM, tuvo como objetivo pronosticar la concentración horaria de ozono con un horizonte de 24 horas en 13 estaciones de la red, usando únicamente información medida hasta la hora de origen, y evaluar qué tan consistente es la capacidad predictiva entre estaciones.

Se utilizaron 488 029 registros horarios de enero de 2021 a julio de 2026. Los huecos de hasta 24 horas en las predictoras se imputaron con SAITS (Du et al., 2023); el ozono que se pronostica nunca es imputado. Se aplicaron dos técnicas multivariadas: una regresión lineal múltiple sobre $\ln(O_3)$ (dependencia) y un análisis de componentes principales seguido de k-means (interdependencia). La validación fue temporal: entrenamiento 2021–2024 con validación en 2025, y entrenamiento 2021–2025 con prueba en enero–julio de 2026. Los tres pronósticos comparados se evaluaron sobre exactamente las mismas horas y la incertidumbre se cuantificó con un bootstrap por bloques semanales que mantiene juntas todas las estaciones de las mismas fechas (Künsch, 1989).

El modelo completo obtuvo $R^2 = 0.622$ y RMSE $= 12.87$ ppb en 2025, y $R^2 = 0.587$ y RMSE $= 12.72$ ppb en enero–julio de 2026. La ventaja sobre la línea base de persistencia fue de 0.122 de R^2 (IC 95 %: 0.092 a 0.153) en 2025 y de 0.103 (0.064 a 0.150) en 2026; ninguno de los dos intervalos incluye el cero. En cambio, la diferencia frente a un modelo mínimo que solo usa el ozono de origen, la hora, el mes y la estación fue de 0.004 (-0.006 a 0.013) y 0.012 (-0.002 a 0.029): la meteorología y los precursores medidos en el origen no producen una mejora distinguible del azar.

Con el umbral horario de 58 ppb de la NOM-172-SEMARNAT-2023, el modelo detectó el 46.2 % de las horas excedidas en 2025 y el 43.3 % en 2026, frente al 56.8 % y 52.6 % de la persistencia, con menos falsas alarmas (2 320 contra 3 035 en 2025). Con el límite horario de 90 ppb de la NOM-020-SSA1-2021 la brecha aumenta (9.4 % contra 29.5 % en 2025). El análisis PCA–k-means describió tres perfiles de días; la silueta baja (0.250) indica separación débil y el mayor RMSE se observó en el perfil con más precursores y menor humedad (15.85 y 14.89 ppb). Se recomienda usar el modelo para ordenar horas por riesgo y no como sistema de alerta, incorporar pronósticos meteorológicos para el instante objetivo y calibrar el umbral de alerta con SIMA. Entre las limitaciones están la autocorrelación de los residuos, la multicolinealidad entre rezagos, la cobertura desigual entre estaciones y que 2026 solo cubre hasta julio.

Introducción y justificación

En el Área Metropolitana de Monterrey, las emisiones del tráfico y la industria, junto con la topografía del valle, condicionan la acumulación de contaminantes. El ozono troposférico (O_3) se forma a partir de precursores como los NO_x y los compuestos orgánicos volátiles bajo radiación solar y temperaturas altas, por lo que depende tanto de las emisiones como de la meteorología.

Conviene precisar dos términos que se usan a lo largo del informe. La meteorología describe el estado de la atmósfera en escalas de horas a pocos días, que es lo que mide SIMA cada hora; el clima es el promedio de esas condiciones durante periodos largos, convencionalmente de al menos 30 años (Hong Kong Observatory, s.f.). Este trabajo utiliza variables meteorológicas medidas y no caracteriza el clima de la región.

La relevancia del problema puede dimensionarse con el criterio de la propia norma de salud. La NOM-020-SSA1-2021 evalúa el ozono mediante el máximo anual del promedio móvil de ocho horas. Aplicando sus criterios de suficiencia a las 12 estaciones que los cumplen en los cinco años completos, la mediana del máximo anual pasó de 97.2 ppb en 2021 a 111.1 ppb en 2025, y las 12 rebasaron el límite vigente en cada uno de esos años (Figura 1). Anticipar la concentración horaria con 24 horas de antelación permitiría a SIMA informar a la población con mayor oportunidad. Este reto aplica CRISP-DM para construir ese pronóstico y caracterizar las condiciones asociadas con su error.

Problemática y objetivos

Problemática

Se busca pronosticar O_3 horario con 24 horas de anticipación a partir de meteorología, precursores y calendario medidos hasta la hora de origen, evaluar la consistencia entre estaciones y medir la detección de horas por encima de los umbrales horarios de la normatividad vigente. La cobertura es desigual: NO3 y NTE registraron menos del 40 % de las horas posibles y quedaron fuera; entre las 13 estaciones conservadas, NE y SO presentan lagunas largas.

Un aspecto central del planteamiento es qué información está disponible al momento de

emitir el pronóstico. Todas las predictoras se miden en la hora de origen t o antes; del instante objetivo $t + 24$ solo se conocen de antemano la hora y el mes. No se emplean pronósticos meteorológicos para $t + 24$, de modo que el modelo podría operarse en tiempo real con la información que SIMA ya tiene registrada, salvo la imputación, que usa horas posteriores.

Objetivo general y objetivos específicos

Objetivo general. Pronosticar O_3 horario a 24 horas en 13 estaciones SIMA con cobertura suficiente (2021–2026), usando variables meteorológicas, NO, NO_2, CO y calendario medidos en el origen, y evaluar el desempeño temporal y entre estaciones frente a una línea base de persistencia.

Objetivos específicos.

- Integrar, limpiar e imputar los datos horarios de SIMA para construir una base de modelado.
- Ajustar una regresión lineal múltiple interpretable para predecir el ozono a 24 horas y evaluarla con R^2 y MSE bajo validación temporal, con intervalos que respeten la dependencia temporal.
- Identificar perfiles de condiciones meteorológicas y de precursores mediante PCA y k-means, y relacionarlos con el error del pronóstico.
- Evaluar el desempeño por estación y la detección de horas y episodios por encima de los umbrales horarios de 58 y 90 ppb.

Datos y preparación de la base de datos

Fuente y periodo de los datos

La base reúne 488 029 registros horarios (estación-hora) de 13 estaciones SIMA, de enero de 2021 a julio de 2026 (Secretaría de Medio Ambiente del Estado de Nuevo León, 2026). Las estaciones son CE, NE, NE2, NE3, NO, NO2, NTE2, SE, SE2, SE3, SO, SO2 y SUR. Se excluyeron NTE y NO3 por cobertura menor al 40 % y el año 2020 porque el 58.6 % de sus horas carece de O_3.

Contexto geográfico de las estaciones de monitoreo

Las 13 estaciones del SIMA analizadas en el Área Metropolitana de Monterrey (AMM) se ubican entre los 334 msnm (SE3 en Cadereyta) y los 702 msnm (NO2 en García) —detalle disponible en el Anexo A—. Esta red vigila zonas con entornos diversos: CE (Obispado) mide tráfico e industrias; NO (San Bernabé) se halla a favor del viento al oeste de fuentes industriales (Gobierno del Estado de Nuevo León, 2016); SE3 monitorea la refinería de Cadereyta; y NE3 evalúa el impacto de una termoeléctrica y del aeropuerto en Pesquería. Asimismo, estaciones como NE3, NO2, SO, CE y NTE2 se localizan en los municipios con mayores emisiones de PM2.5 (INECC, 2021). El relieve del AMM —una llanura rodeada por la Sierra Madre Oriental, el Cerro de las Mitras, el Cerro del Topo Chico y el Cerro de la Silla, con alturas de hasta 1,820 msnm— condiciona la calidad del aire al limitar la circulación del viento, favorecer la acumulación de contaminantes y canalizarlos hacia el suroeste; esto resulta clave para el ozono, cuya formación depende de la radiación y temperatura, y su dispersión, del viento (variables empleadas por el modelo; Gobierno del Estado de Nuevo León, 2023).

Preparación y calidad de los datos

Los huecos de hasta 24 horas se imputaron con SAITS (Du et al., 2023), una red de autoatención para series multivariadas que estima cada valor faltante a partir de las horas y variables cercanas; los huecos más largos se conservaron como faltantes. En una prueba con bloques ocultos de 2026, SAITS tuvo menor error que la interpolación lineal conforme crece el hueco (0.41 frente a 0.58 desviaciones estándar en huecos de 24 horas). Se excluyeron las filas sin ozono observado y las filas con predictoras faltantes, de modo que los tres pronósticos se evalúan sobre la misma muestra.

Como SAITS utiliza horas posteriores al hueco, se verificó que la imputación no inflara los resultados: en 2025 el 8.6 % de las horas evaluadas tiene alguna predictora imputada y, al excluirlas, el R^2 pasa de 0.622 a 0.619; en 2026, con 6.7 % de horas imputadas, permanece en 0.587. La variable respuesta nunca se imputa.

Se excluyeron RAINF ($r = -0.008$ con O_3) y NO_x, casi equivalente a NO+NO_2. Como análisis de sensibilidad se identificaron las lecturas de NO que rebasan el rango de operación anual documentado por SIMA (350 ppb en 2021, 400 en 2022, 500 en 2023, 400 en 2024 y 350 en 2025): son 28 registros, concentrados en NE2 (15 en 2025), NO (8 en 2022), SO (3 en 2025), SE2 y SO2 (1 cada una en 2024). Las lecturas no se eliminaron de la base; solo se excluyeron para reajustar el modelo y comprobar su influencia. Se transformaron temperatura, humedad, radiación y viento según se describe en la metodología; las variables del PCA se transformaron con $\log(1 + x)$ en los precursores y se centraron por estación antes de estandarizarse.

Variables de contaminantes y meteorológicas

La respuesta es O_3 a 24 horas (ppb; se modela $\ln(O_3)$). Las predictoras incluyen O_3 en el origen; temperatura TOUT (°C), humedad RH (%), radiación SR (kW/m^2), presión PRS (mmHg), velocidad WSR (km/h) y dirección del viento; CO (ppm), NO y NO_2 (ppb); hora y mes objetivo, estación como efecto fijo, y rezagos de 1–3 horas de O_3 y NO_2.

Metodología: modelación y validación

Flujo de trabajo CRISP-DM

Se definió el problema con el socio formador, se integraron y limpiaron los datos, se imputaron los huecos cortos, se construyó la base de modelado y se exploraron las relaciones entre ozono, meteorología y precursores. Después se ajustó el objetivo a la cobertura disponible, se validó temporalmente y se compararon los resultados con una línea base. La fase de despliegue no se desarrolló en esta etapa: los resultados se entregan como código reproducible y como este informe.

Umbrales utilizados

Los umbrales se tomaron de normas vigentes y corresponden al promedio horario, que es la magnitud que pronostica el modelo. El umbral principal es 58 ppb, valor en el que termina la banda "Buena" y comienza la "Aceptable" del Índice AIRE Y SALUD para el promedio de una hora (Secretaría de Medio Ambiente y Recursos Naturales [SEMARNAT], 2024, Tabla 6). El umbral

normativo es 90 ppb, límite horario de protección a la salud de la NOM-020-SSA1-2021 (Secretaría de Salud, 2021, Tabla 1), que coincide con el inicio de la banda "Mala" del mismo índice. Una hora excedida es una hora cuyo O_3 medido supera el umbral; una alerta, una hora cuyo pronóstico lo supera; una falsa alarma, una alerta en una hora que no fue excedida, y un episodio, una racha de horas excedidas consecutivas en una misma estación, que se da por detectado si hubo alerta en al menos una de sus horas. Para la tendencia histórica (Figura 1) se usó el indicador de ocho horas de la misma NOM-020, con sus criterios de suficiencia: ventana válida con al menos 6 de 8 horas, máximo diario válido con al menos 18 ventanas, año válido con al menos el 75 % de los días e indicador anual igual al máximo de los máximos diarios.

Técnica de relaciones de dependencia

Regresión lineal múltiple. Se modeló $\ln(\mathrm{O_3})$ a 24 horas con efectos de hora, mes y estación; transformaciones de temperatura, humedad, radiación y viento; presión, NO, NO_2, CO y rezagos horarios de O_3 y NO_2 (Iglesias-Gonzalez et al., 2020; Liu et al., 2025). Se modela el logaritmo porque la respuesta es positiva y asimétrica, lo que vuelve la distribución más simétrica y mantiene positivas las predicciones. Las predicciones se retransformaron a ppb con el factor de smearing de Duan (1983), igual a 1.1281 en el ajuste 2021–2024 y 1.1327 en el ajuste 2021–2025. En el resto del informe, este modelo se denomina *modelo completo*.

Pronósticos comparados. Se compararon tres pronósticos sobre exactamente las mismas horas: la *persistencia*, $\widehat{O}_{3,t+24} = O_{3,t}$, que repite el valor de 24 horas antes y corresponde al método ingenuo estacional (Hyndman y Athanasopoulos, 2021); el *modelo mínimo*, una regresión con el ozono de origen, la hora, el mes y la estación; y el *modelo completo* descrito arriba. La igualdad de muestras se verifica en el código antes de comparar.

Validación. La validación fue temporal: entrenamiento 2021–2024 y validación en 2025; después, entrenamiento 2021–2025 y prueba en enero–julio de 2026. No se usó validación cruzada aleatoria porque las horas están autocorrelacionadas y repartirlas al azar haría que una hora de prueba tuviera a sus vecinas en el entrenamiento, subestimando el error. Se calcularon MAE, RMSE, MSE, R^2 y sesgo, globales y por estación, además de AUC y proporción de horas y

episodios detectados en cada umbral.

Cuantificación de la incertidumbre. Como los residuos están autocorrelacionados, las horas no son independientes y los intervalos calculados bajo ese supuesto resultarían demasiado estrechos. Se empleó un bootstrap por bloques (Künsch, 1989): el periodo se dividió en bloques de siete días según la fecha objetivo (53 en 2025 y 31 en 2026), manteniendo juntas todas las estaciones de esas fechas porque comparten la meteorología regional; los bloques se remuestrearon con reemplazo 2 000 veces y se recalcularon las métricas, de forma pareada entre pronósticos. Los intervalos son los percentiles 2.5 y 97.5.

Diagnósticos. Los diagnósticos del ajuste 2021–2024 indican linealidad aceptable tras las transformaciones, pero no se cumplen la homocedasticidad (la desviación estándar del residuo logarítmico baja de 0.726 a 0.349 entre el primer y el último decil; Breusch–Pagan la rechaza), la normalidad ni la independencia (ACF promedio de los residuos de 0.859, 0.670 y 0.503 en los rezagos 1–3); las figuras correspondientes se presentan en el Anexo B. También hay GVIF elevados entre rezagos (hasta 25.67) y entre presión y estación (Anexo C, Tabla 6). Estos resultados invalidan la inferencia convencional, por lo que no se reportan valores p ni estadísticos F. El desempeño predictivo se establece con las pruebas temporales y los intervalos por bloques, que no requieren esos supuestos. Esto no significa que los incumplimientos carezcan de efecto sobre el pronóstico: el factor de smearing constante es una aproximación bajo heterocedasticidad y el modelo, al estimar una media condicional, suaviza los valores extremos.

Técnica de relaciones de interdependencia

PCA y k-means (análisis exploratorio). Se agruparon observaciones día-estación a partir de diez variables meteorológicas y de precursores. Un día-estación entra al análisis si tiene al menos 18 horas con las diez variables con dato, por analogía con el criterio de suficiencia diaria de la NOM-020-SSA1-2021; con ese filtro quedan 20 179 días-estación, de los cuales 15 861 corresponden a 2021–2024 y se usaron para ajustar. Las variables se centraron por estación, de modo que los perfiles no reflejen simplemente la ubicación, y se estandarizaron. El PCA redujo la dimensión antes de aplicar k-means (James et al., 2021, cap. 12) con el algoritmo de Hartigan y Wong (1979).

Beaver y Palazoglu (2006) propusieron un algoritmo de agrupamiento basado en PCA, extensión de k-means, para series horarias de viento de la bahía de San Francisco, y relacionaron los grupos con el ozono máximo de ocho horas. Stolz et al. (2020) combinaron PCA, agrupamiento jerárquico y k-means en un ensamble aplicado a series de O_3 y PM_{10} de las tres mayores zonas metropolitanas de México, incluida Monterrey, para identificar estaciones similares o redundantes. Aquí la unidad es día-estación y el fin es describir perfiles asociados con el error, no predecir ni establecer causalidad.

Evaluación exploratoria. La prueba de esfericidad de Bartlett (1954; $\chi^2 = 40{,}728$, 45 gl) y la medida de adecuación muestral de Kaiser–Meyer–Olkin (Kaiser, 1970; KMO $= 0.681$) describen una estructura de correlaciones adecuada para el PCA; no validan k-means. Se retuvieron **cinco componentes**, que explican el 76.8 % de la varianza, con el criterio del codo del gráfico de sedimentación (Cattell, 1966): los autovalores cuarto y quinto son casi iguales (0.933 y 0.923) y la mayor caída restante ocurre después del quinto. Se eligió $k = 3$ por el codo de la suma de cuadrados dentro de los grupos, que cae 12 602 de $k = 2$ a $k = 3$ y 6 427 de $k = 3$ a $k = 4$ (Anexo D). Su silueta promedio (Rousseeuw, 1987), calculada sobre una muestra aleatoria de 3 000 días-estación, de 0.250 es la segunda más alta después de $k = 2$ e indica separación débil, por lo que los grupos se interpretan como perfiles descriptivos sobre un continuo y no como grupos naturales; el índice de Rand ajustado (Hubert y Arabie, 1985) entre dos inicializaciones fue 1.000, lo que describe reproducibilidad de la partición y no la existencia de grupos. El modelo se ajustó con 2021–2024 y las observaciones posteriores se asignaron al centroide más cercano.

Técnicas exploradas sin resultados factibles

Se exploró agrupar con k-means a las estaciones, pero con solo 13 la solución resultó inestable, por lo que se agruparon observaciones día-estación. También se probaron particiones con más grupos: desde $k = 4$ la silueta cae por debajo de 0.19 y el índice de Rand ajustado entre inicializaciones baja a 0.395 en $k = 4$ y 0.512 en $k = 7$, de modo que se conservó $k = 3$ (Anexo D).

Resultados

Descripción exploratoria de los datos

La base contiene 488 029 registros de 13 estaciones (enero de 2021–julio de 2026). El ozono presenta un ciclo diario marcado, con mínimo hacia las 7 h y máximo hacia las 15 h, y una autocorrelación de 0.74 a las 24 horas (Anexo E), que es la razón por la cual la persistencia constituye una línea base exigente. Sus correlaciones lineales con las predictoras son de 0.54 con la radiación solar, 0.48 con la temperatura, -0.57 con la humedad relativa, -0.29 con NO, -0.25 con NO_2 y -0.06 con CO. RAINF tuvo una correlación con O_3 de $r = -0.008$, por lo que no se incluyó en el PCA.

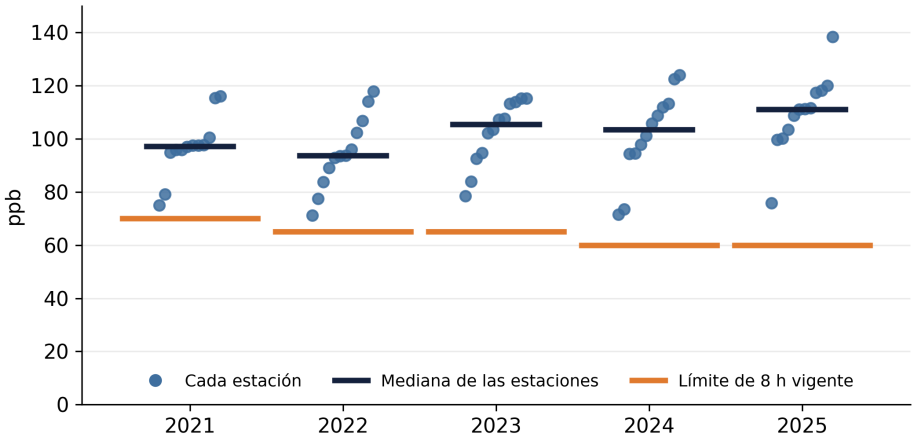


Figura 1: Máximo anual del promedio móvil de ocho horas de O_3 por estación, con los criterios de suficiencia de la NOM-020-SSA1-2021. Se incluyen las 12 estaciones que cumplen el mínimo del 75 % de días válidos en los cinco años.

Relaciones entre contaminantes y variables meteorológicas

Dependencia. La hora objetivo, el mes objetivo y el O_3 en el origen concentran el 88.7 % del aumento de la suma de cuadrados residual al retirar cada término del modelo, seguidos por la estación (5.2 %) y, muy por detrás, por NO, la dirección del viento, la presión y CO (Anexo F, Tabla 8). Es decir, el ajuste se explica sobre todo por el ciclo diario y anual y por el nivel de ozono de partida. Este reparto es un resumen descriptivo: la autocorrelación de los residuos impide

interpretarlo como evidencia de significancia estadística, y la mejora predictiva se establece frente a la línea base en los periodos de prueba.

Interdependencia. Los tres perfiles se describen con criterios observables, sin asignarles etiquetas climatológicas (Tabla 1). El perfil 1 reúne los días con la temperatura media más baja y la humedad más alta, y se concentra de octubre a febrero; el perfil 2, los de precursores más altos y humedad más baja, de octubre a marzo; el perfil 3, los de temperatura más alta, más viento y menos precursores, de abril a septiembre. Como la unidad es el día-estación, cada perfil describe el día completo y no horas específicas. El perfil 2 coincide con el mayor error del pronóstico; este patrón es descriptivo y no demuestra causalidad ni capacidad predictiva de los conglomerados.

Tabla 1: Criterios observables de cada perfil de k-means (medias diarias) y error del pronóstico

Perfil	Días	TOUT (°C)	RH (%)	WSR (km/h)	NO (ppb)	NO_2 (ppb)	CO (ppm)	RMSE (ppb)
Perfil 1	4 593	16.59	68.24	7.22	9.18	14.29	1.14	11.94
Perfil 2	5 466	22.22	47.23	7.15	15.40	20.98	1.52	15.85
Perfil 3	10 120	27.38	56.65	10.04	5.46	9.11	1.04	11.66

Nota. NO, NO_2 y CO se promedian en escala $\log(1 + x)$, por lo que son medias geométricas. El RMSE es el de la validación de 2025.

Comparación con la línea base de persistencia

La Tabla 2 resume lo obtenido. El modelo completo alcanzó $R^2 = 0.622$ y RMSE $= 12.87$ ppb en 2025, y $R^2 = 0.587$ y RMSE $= 12.72$ ppb en enero–julio de 2026, con sesgo pequeño y negativo (-0.87 y -0.46 ppb). La persistencia se quedó en $R^2 = 0.500$ y 0.484, con RMSE de 14.80 y 14.21 ppb. La reducción del error cuadrático medio respecto de la persistencia fue de 24.4 % (IC 95 %: 20.2 a 28.1) en 2025 y de 19.9 % (14.0 a 25.5) en 2026.

El modelo mínimo, que solo usa el ozono de origen, la hora, el mes y la estación, obtuvo $R^2 = 0.618$ y 0.575. La diferencia entre el modelo completo y el mínimo fue de 0.004 (IC 95 %: -0.006 a 0.013) en 2025 y de 0.012 (-0.002 a 0.029) en 2026: ambos intervalos incluyen el

cero, por lo que la meteorología y los precursores medidos en el origen no aportan una mejora distinguible del azar. Una explicación plausible es que el modelo utiliza las condiciones de hoy y no pronósticos para mañana, y que la hora y el mes ya capturan buena parte del ciclo de radiación y temperatura.

Tabla 2: Desempeño de los tres pronósticos sobre las mismas horas, con intervalos de confianza del 95 % por bootstrap de bloques semanales

Periodo	Pronóstico	R^2	IC 95 % de R^2	RMSE (ppb)
2025 (completo)	Persistencia	0.500	[0.444, 0.552]	14.80
	Modelo mínimo	0.618	[0.586, 0.649]	12.93
	Modelo completo	0.622	[0.588, 0.652]	12.87
2026 (ene–jul)	Persistencia	0.484	[0.388, 0.568]	14.21
	Modelo mínimo	0.575	[0.506, 0.636]	12.89
	Modelo completo	0.587	[0.523, 0.644]	12.72

Nota. $N = 69{,}618$ horas en 2025 y $N = 27{,}989$ en 2026. Diferencia del modelo completo frente a la persistencia: 0.122 [0.092, 0.153] y 0.103 [0.064, 0.150]; frente al modelo mínimo: 0.004 [-0.006, 0.013] y 0.012 [-0.002, 0.029].

Desempeño por estación

La Figura 2 compara el R^2 del modelo completo y de la persistencia por estación en enero–julio de 2025 y de 2026, para una buena comparación. En 2025 el modelo supera a la persistencia en las 13 estaciones, con R^2 de 0.397 a 0.784; en 2026 lo hace en ocho de las nueve estaciones con datos; la excepción es NE3 (0.429 contra 0.499), y en SE2 el desempeño es prácticamente igual (0.436 contra 0.428).

Las comparaciones por estación están condicionadas por la cobertura. Se reportan todas y se marcan con asterisco las que tienen menos del 75 % de las horas del periodo, por analogía con el mínimo de suficiencia de la NOM-020-SSA1-2021. NE es el caso extremo, con el 6.8 % de las horas de enero–julio de 2025: su R^2 aparentemente alto se apoya en muy pocas observaciones. En

2026 no hay datos para NE, NO2, SE3 ni SO.

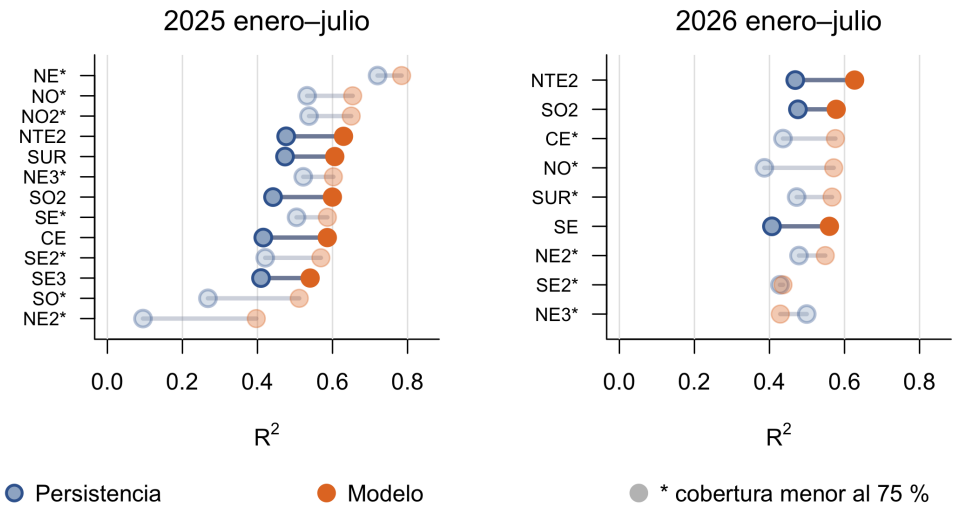


Figura 2: R^2 del modelo completo y de la persistencia por estación en enero–julio de 2025 y de 2026. Las estaciones con asterisco y en tono claro tienen menos del 75 % de las horas del periodo.

Detección de horas y episodios excedidos

La Tabla 3 presenta la matriz de confusión en los dos umbrales, y el Anexo G muestra la ubicación temporal de los errores en cada estación. Con el umbral principal de 58 ppb, el modelo detectó el 46.2 % de las horas excedidas de 2025 y el 43.3 % de las de 2026, frente al 56.8 % y 52.6 % de la persistencia; la diferencia a favor de la persistencia es de 10.5 puntos (IC 95 %: 5.3 a 15.5) y 9.2 puntos (1.9 a 16.0). A cambio, el modelo emite menos falsas alarmas (2 320 contra 3 035 en 2025) y su precisión es ligeramente mayor (57.9 % contra 56.3 %). En episodios, con duración mediana de 4 horas en 2025 y 3 en 2026, el modelo detectó el 58.1 % y el 51.6 %, y la persistencia el 67.2 % y el 61.9 %.

Tabla 3: Matriz de confusión del modelo completo y de la persistencia en los dos umbrales horarios

Umbral	Pronóstico y periodo	Excedidas	VP	FN	FP	Sens. (%)	Prec. (%)
58 ppb	Modelo 2025	6 894	3 188	3 706	2 320	46.2	57.9
	Persistencia 2025	6 894	3 915	2 979	3 035	56.8	56.3
	Modelo 2026	2 220	962	1 258	836	43.3	53.5
	Persistencia 2026	2 220	1 167	1 053	1 030	52.6	53.1
90 ppb	Modelo 2025	985	93	892	83	9.4	52.8
	Persistencia 2025	985	291	694	692	29.5	29.6
	Modelo 2026	358	22	336	22	6.1	50.0
	Persistencia 2026	358	118	240	251	33.0	32.0

Nota. VP: alerta en hora excedida.

Con el umbral normativo de 90 ppb la brecha se amplía: el modelo detectó el 9.4 % de las horas excedidas de 2025 y el 6.1 % de las de 2026, frente al 29.5 % y 33.0 % de la persistencia, aunque con mayor precisión (52.8 % contra 29.6 % en 2025). Su AUC (0.930 y 0.931 con 58 ppb; 0.940 y 0.951 con 90 ppb) indica que ordena bien las horas por riesgo aun cuando emita pocas alertas: el contraste refleja que, al estimar una media condicional, rara vez pronostica valores muy altos. Para separar el efecto del umbral del efecto del número de alertas, se eligió con 2025 el umbral del modelo que produce tantas alertas como la persistencia y se aplicó sin cambios a 2026. Con 58 ppb ese umbral equivalente es 55.01 ppb y la detección resulta prácticamente igual (55.2 % contra 56.8 % en 2025 y 53.1 % contra 52.6 % en 2026); con 90 ppb es 74.48 ppb y el modelo sigue por debajo (25.3 % contra 29.5 %).

Error por perfil de condiciones

El perfil 2, con los precursores más altos y la menor humedad, presentó el mayor error en ambos periodos y la mayor proporción de horas excedidas (Tabla 4). El perfil 3 tiene el mayor R^2, pero también el mayor número absoluto de horas excedidas no detectadas (1 850 en 2025),

porque reúne más de la mitad de las horas evaluadas. Estos resultados son descriptivos y sirven para identificar cuándo conviene desconfiar más del pronóstico. En el perfil 1, el modelo detecta solo el 12.8 % y el 8.3 % de las horas excedidas, que representan el 4.9 % y el 5.5 % de sus horas.

Tabla 4: Error del modelo por perfil de k-means (2025 / 2026 ene–jul)

Perfil	RMSE (ppb)	R^2	Horas excedidas (%)	Horas detectadas (%)
Perfil 1	11.94 / 12.60	0.56 / 0.52	4.9 / 5.5	12.8 / 8.3
Perfil 2	15.85 / 14.89	0.59 / 0.55	14.4 / 11.2	50.3 / 54.1
Perfil 3	11.66 / 11.65	0.64 / 0.63	9.9 / 7.6	50.6 / 48.2

Nota. Umbral de 58 ppb. Quedaron sin perfil asignado 876 de 69 618 horas en 2025 y 280 de 27 989 en 2026.

Análisis de sensibilidad

Al reajustar el modelo sin las 28 lecturas de NO fuera del rango de operación de SIMA, el R^2 de 2025 pasó de 0.622 a 0.623; el modelo original evaluado sobre esas mismas horas da el mismo valor, por lo que el cambio proviene de las horas excluidas y no del reajuste. Al excluir las horas con alguna predictora imputada, el R^2 pasó de 0.622 a 0.619 en 2025 y permaneció en 0.587 en 2026. Ninguno de los dos factores altera de forma apreciable el desempeño

Discusión y conclusiones

Discusión de los hallazgos

El modelo supera a la persistencia en ambos periodos de prueba, y los intervalos bootstrap de la diferencia en R^2 excluyen el cero, por lo que la ventaja se mantiene al remuestrear las semanas evaluadas. Sin embargo, la descomposición entre el modelo mínimo y el completo muestra que casi toda esa ventaja proviene del ozono en el origen y del calendario, y no de la meteorología ni de los precursores medidos.

En la detección de excedencias, la persistencia es superior en sensibilidad con ambos umbrales, aunque el modelo produce menos falsas alarmas. Su AUC (0.930 y 0.931 con 58 ppb; 0.940 y 0.951 con 90 ppb) es ligeramente mayor que el de la persistencia (0.916 y 0.920; 0.936 y

0.943), lo que indica que ordena las horas por riesgo al menos tan bien como ella aun cuando emita pocas alertas. El experimento con el mismo número de alertas muestra que, con 58 ppb, buena parte de la diferencia proviene de cuántas alertas emite cada método y no de su capacidad de discriminar; con 90 ppb la diferencia persiste y es coherente con que un modelo de media condicional rara vez pronostique valores muy altos. Los perfiles PCA–k-means, por su parte, son descriptivos: la silueta baja indica un continuo de condiciones más que conglomerados naturales, y su utilidad es señalar que el error aumenta en los días con más precursores y menor humedad.

Limitaciones

La heterocedasticidad, la no normalidad, la autocorrelación (ACF $= 0.859$ en el rezago 1) y la multicolinealidad (GVIF hasta 25.67) limitan la inferencia usual. Las métricas de prueba describen el desempeño observado en 2025 y 2026, pero no garantizan el mismo comportamiento en otros periodos. El pronóstico usa meteorología medida en el origen, no pronosticada, lo que acota el aporte posible de esas variables. La cobertura es desigual: varias estaciones quedan por debajo del 75 % de las horas del periodo evaluado y NO3 y NTE se excluyeron por tener menos del 40 %. El año 2026 solo cubre hasta julio, por lo que sus cifras no son comparables con un año completo. La silueta baja (0.250) indica perfiles poco separados; Bartlett y el KMO informan sobre la estructura para el PCA y no validan el k-means. El indicador de ocho horas asigna los límites por año calendario, mientras que la norma cuenta sus plazos desde su entrada en vigor; es una aproximación.

Conclusiones y recomendaciones

Es posible pronosticar la concentración horaria de ozono con 24 horas de antelación usando únicamente información medida hasta la hora de origen: el modelo explica cerca del 60 % de la variación ($R^2 = 0.622$ en 2025 y 0.587 en enero–julio de 2026) y supera a la persistencia por 0.122 y 0.103 de R^2, con intervalos que no incluyen el cero y de forma consistente en casi todas las estaciones. Lo que quedó débil es la detección de picos, donde la persistencia es superior en sensibilidad, y el aporte de la meteorología medida, que no se distingue del modelo mínimo.

Recomendaciones para el socio formador: Usar el modelo actual para ordenar horas por riesgo de ozono y no como sistema de alerta, dada la proporción de horas excedidas detectadas. Incorporar pronósticos meteorológicos para el instante objetivo, que es la información que hoy falta. Probar modelos que capturen no linealidades y valores extremos, como la regresión cuantílica o los árboles potenciados, bajo las mismas particiones temporales. Calibrar con SIMA el umbral de alerta según el costo relativo de una falsa alarma y de una excedencia no detectada; el experimento con el mismo número de alertas es un punto de partida. Corregir la autocorrelación con errores robustos, bloques temporales o errores ARMA estacionales, como en Iglesias-Gonzalez et al. (2020), y evaluar si ajustar modelos por perfil reduce el error en los días con más precursores.

Preguntas futuras

¿Cuánto mejora el pronóstico al incorporar pronósticos meteorológicos para el instante objetivo? ¿Cuánto mejora la detección de picos con un modelo no lineal y a qué costo en interpretabilidad? ¿Qué umbral de alerta conviene a SIMA según el costo relativo de cada tipo de error? ¿Qué procesos explican el mayor error del perfil con más precursores, y se mantiene el desempeño con horizontes de 1, 6 o 12 horas?

Declaración de uso de inteligencia artificial

Opción B. Se utilizó IA de la siguiente forma.

Herramienta: se utilizó Prism de OpenAI para la estructura del documento.

Uso realizado: darle formato al documento y ayuda en la sintaxis de LaTeX

Secciones donde se utilizó: se utilizó en todas las secciones.

Validación realizada por los estudiantes: ejecutamos el código en R con el conjunto de datos de SIMA que imputamos, revisamos los resultados obtenidos y verificamos que las interpretaciones coincidieran con ellos.

Confirmación: El equipo confirma que revisó y verificó el contenido de este trabajo y asume la responsabilidad del contenido final entregado.

Referencias

Bartlett, M. S. (1954). A note on the multiplying factors for various χ^2 approximations. *Journal of the Royal Statistical Society: Series B (Methodological), 16*(2), 296–298. https://doi.org/10.1111/j.2517-6161.1954.tb00174.x

Beaver, S., & Palazoglu, A. (2006). Cluster analysis of hourly wind measurements to reveal synoptic regimes affecting air quality. *Journal of Applied Meteorology and Climatology, 45*(12), 1710–1726. https://doi.org/10.1175/JAM2437.1

Cattell, R. B. (1966). The scree test for the number of factors. *Multivariate Behavioral Research, 1*(2), 245–276.

Du, W., Côté, D., & Liu, Y. (2023). SAITS: Self-attention-based imputation for time series. *Expert Systems with Applications, 219*, Artículo 119619. https://doi.org/10.1016/j.eswa.2023.119619

Duan, N. (1983). Smearing estimate: A nonparametric retransformation method. *Journal of the American Statistical Association, 78*(383), 605–610.

Gobierno del Estado de Nuevo León. (2016). *Programa de Gestión para Mejorar la Calidad del Aire del Estado de Nuevo León 2016–2025 (ProAire)*. Secretaría de Desarrollo Sustentable.

Gobierno del Estado de Nuevo León. (2023). *Programa Integral de Gestión para Mejorar la Calidad del Aire del Estado de Nuevo León 2023–2033 (PIGECA)*. Secretaría de Medio Ambiente del Estado de Nuevo León.

Hartigan, J. A., & Wong, M. A. (1979). Algorithm AS 136: A k-means clustering algorithm. *Journal of the Royal Statistical Society. Series C (Applied Statistics), 28*(1), 100–108. https://doi.org/10.2307/2346830

Hong Kong Observatory. (s.f.). *What is the difference between weather and climate?* https://www.weather.gov.hk/en/climate_change/faq/faq011.htm

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.).

OTexts. https://otexts.com/fpp3/

Iglesias-Gonzalez, S., Huertas-Bolanos, M. E., Hernandez-Paniagua, I. Y., & Mendoza, A. (2020). Explicit modeling of meteorological explanatory variables in short-term forecasting of maximum ozone concentrations via a multiple regression time series framework. *Atmosphere, 11*(12), Artículo 1304. https://doi.org/10.3390/atmos11121304

Instituto Nacional de Ecología y Cambio Climático [INECC]. (2021). *Estudio para el rediseño de la red de monitoreo de la calidad del aire de Monterrey*. INECC.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2.ª ed.). Springer.

Kaiser, H. F. (1970). A second generation little jiffy. *Psychometrika, 35*(4), 401–415. https://doi.org/10.1007/BF02291817

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics, 17*(3), 1217–1241. https://doi.org/10.1214/aos/1176347265

Liu, Z., Lu, Z., Zhu, W., Yuan, J., Cao, Z., Cao, T., Liu, S., Xu, Y., & Zhang, X. (2025). Comparison of machine learning methods for predicting ground-level ozone pollution in Beijing. *Frontiers in Environmental Science, 13*, Artículo 1561794. https://doi.org/10.3389/fenvs.2025.1561794

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Secretaría de Medio Ambiente del Estado de Nuevo León. (2025). *Ubicación de estaciones de SIMA 2025* [Documento proporcionado por el socio formador].

Secretaría de Medio Ambiente del Estado de Nuevo León. (2026). *Datos horarios de calidad del aire y meteorología del Sistema Integral de Monitoreo Ambiental, 2020–2026* [Conjunto de datos no publicado].

Secretaría de Medio Ambiente y Recursos Naturales [SEMARNAT]. (2024, 25 de enero). *Norma Oficial Mexicana NOM-172-SEMARNAT-2023, Lineamientos para la obtención y comuni-*

cación del índice de calidad del aire y riesgos a la salud. Diario Oficial de la Federación.

Secretaría de Salud. (2021, 28 de octubre). *Norma Oficial Mexicana NOM-020-SSA1-2021, Salud ambiental. Criterio para evaluar la calidad del aire ambiente, con respecto al ozono (O_3)*. Diario Oficial de la Federación. https://sidof.segob.gob.mx/notas/docFuente/5633956

Stolz, T., Huertas, M. E., & Mendoza, A. (2020). Assessment of air quality monitoring networks using an ensemble clustering method in the three major metropolitan areas of Mexico. *Atmospheric Pollution Research, 11*(8), 1271–1280. https://doi.org/10.1016/j.apr.2020.05.005

Anexos

Anexo A. Ubicación de las estaciones

Tabla 5: Estaciones del SIMA utilizadas en el estudio

Clave	Municipio	Latitud (N)	Longitud (O)	Elevación (msnm)
CE	Monterrey	25°40’33”	100°20’18”	562
NE	San Nicolás de los Garza	25°44’41”	100°15’11”	474
NE2	Apodaca	25°46’38”	100°11’17”	432
NE3	Pesquería	25°47’26”	100°04’42”	346
NO	Monterrey	25°45’46”	100°22’09”	568
NO2	García	25°48’01”	100°35’04”	702
NTE2	San Nicolás de los Garza	25°43’47”	100°18’36”	520
SE	Guadalupe	25°39’55”	100°14’37”	500
SE2	Juárez	25°38’45”	100°05’43”	387
SE3	Cadereyta de Jiménez	25°36’04”	99°59’57”	334
SO	Santa Catarina	25°40’32”	100°27’29”	674
SO2	San Pedro Garza García	25°39’54”	100°24’46”	636
SUR	Monterrey	25°37’01”	100°16’26”	555

Nota. Coordenadas y elevaciones tomadas del catálogo de ubicación de estaciones (Secretaría de Medio Ambiente del Estado de Nuevo León, 2025); municipios según el Gobierno del Estado de Nuevo León (2023). Las estaciones NTE (General Escobedo) y NO3 (Monterrey) se excluyeron por cobertura menor al 40 %.

Anexo B. Diagnóstico de residuos

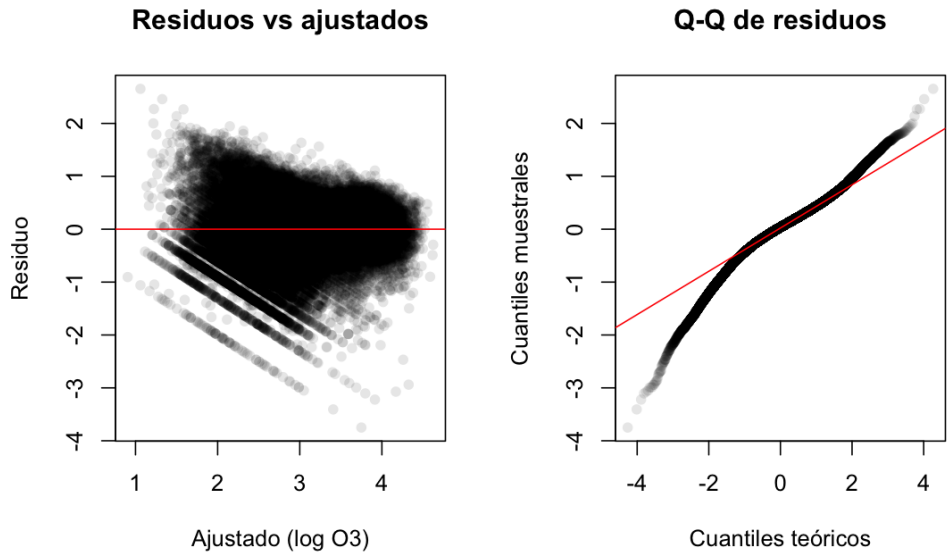


Figura 3: Residuos contra valores ajustados y gráfico Q-Q del modelo completo (ajuste 2021–2024, escala logarítmica; muestra aleatoria de 50 000 horas). Las franjas diagonales corresponden a horas con concentraciones observadas bajas y repetidas.

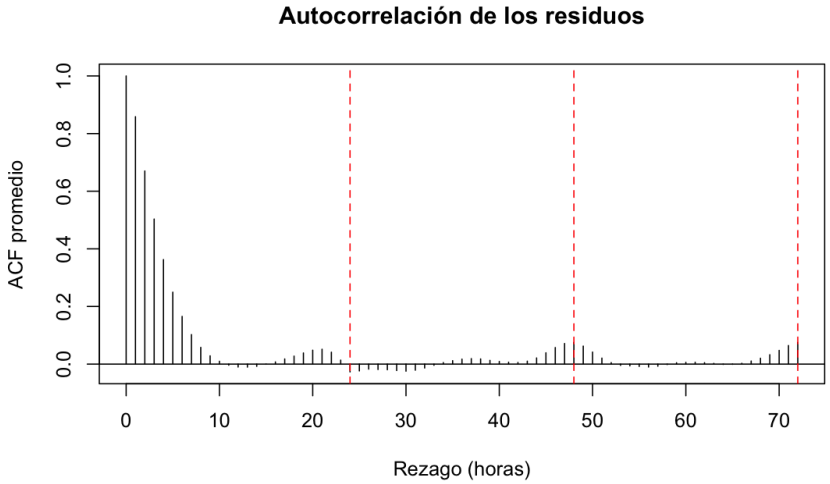


Figura 4: Autocorrelación promedio de los residuos por estación. Las líneas punteadas marcan los rezagos de 24, 48 y 72 horas.

Anexo C. Multicolinealidad

Tabla 6: GVIF del modelo entrenado con los datos de 2021 a 2024

Término	gl	GVIF	$\text{GVIF}^{1/(2\,\text{gl})}$
O_3 en la hora de origen	1	12.27	3.50
$\ln(\text{temperatura} + 273.15)$	1	5.45	2.34
Humedad relativa (polinomio grado 3)	3	3.04	1.20
Radiación solar (polinomio grado 2)	2	5.86	1.56
$1/(\text{velocidad del viento} + 1)$	1	1.60	1.27
Presión	1	12.60	3.55
Desviación angular del viento	1	1.39	1.18
NO	1	1.70	1.31
NO_2	1	9.48	3.08
CO	1	1.55	1.24
Hora del día (factor)	23	18.57	1.07
Mes (factor)	11	4.93	1.08
Estación (factor)	12	24.43	1.14
Rezago 1 de O_3	1	25.67	5.07
Rezago 2 de O_3	1	25.10	5.01
Rezago 3 de O_3	1	11.32	3.36
Rezago 1 de NO_2	1	19.34	4.40
Rezago 2 de NO_2	1	18.97	4.36
Rezago 3 de NO_2	1	8.80	2.97

Nota. Los valores más altos corresponden a los rezagos de O_3 y NO_2, que están fuertemente correlacionados entre sí y con el valor en el origen, y a la presión en presencia del efecto de estación. Por esta razón no se interpretan los coeficientes individuales de esos términos.

Anexo D. Elección del número de componentes y de grupos

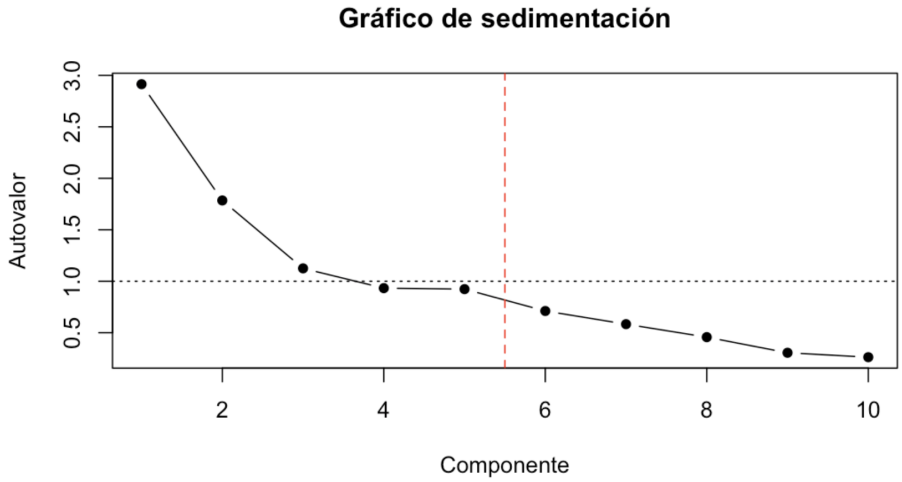


Figura 5: Gráfico de sedimentación del PCA (ajuste 2021–2024). La línea discontinua marca el codo después del quinto componente; los cinco retenidos explican el 76.8 % de la varianza.

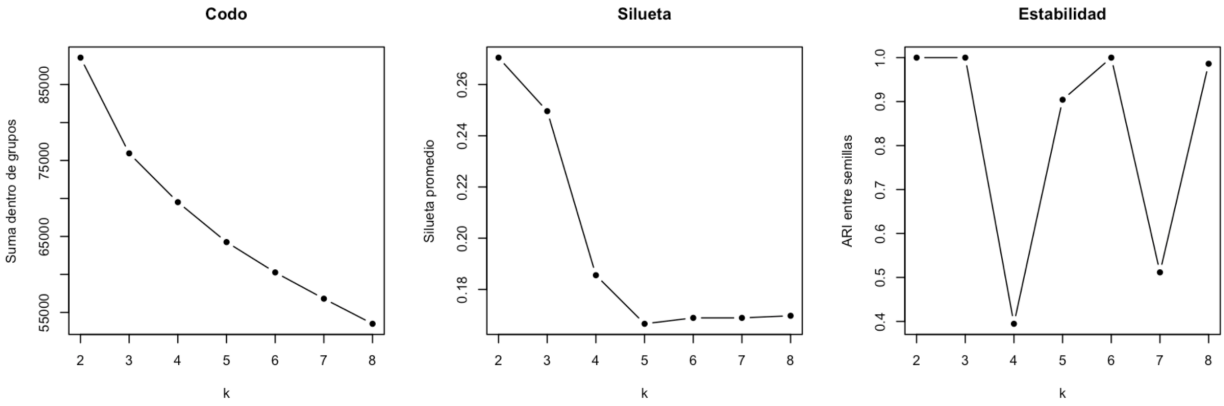


Figura 6: Suma de cuadrados dentro de los grupos, silueta promedio y estabilidad (índice de Rand ajustado entre dos inicializaciones) para $k = 2$ a 8.

Tabla 7: Criterios para elegir k

k	2	3	4	5	6	7	8
Suma dentro	88 542	75 940	69 512	64 258	60 265	56 805	53 501
Silueta	0.271	0.250	0.186	0.167	0.169	0.169	0.170
ARI	1.000	1.000	0.395	0.904	1.000	0.512	0.986
Varianza entre	0.273	0.377	0.429	0.472	0.505	0.534	0.561

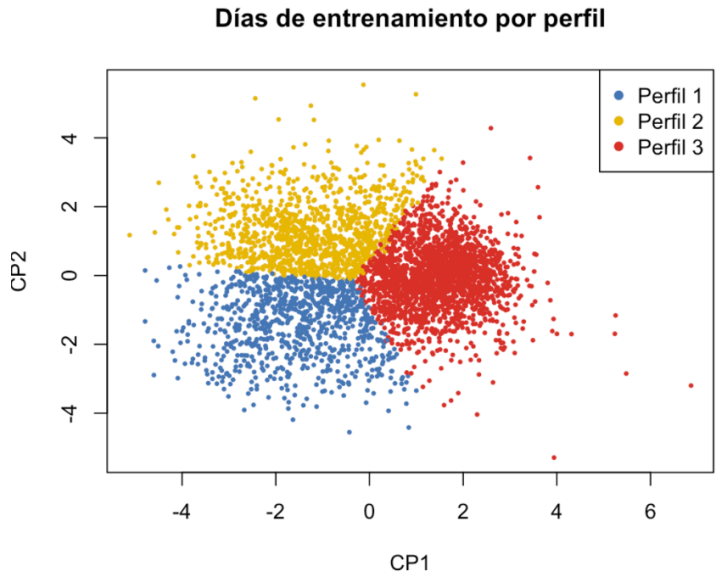


Figura 7: Muestra aleatoria de 4 000 días-estación de entrenamiento (2021–2024) en los dos primeros componentes principales, coloreados por perfil de k-means. La continuidad entre perfiles es coherente con la silueta baja (0.250).

Anexo E. Autocorrelación del ozono por estación

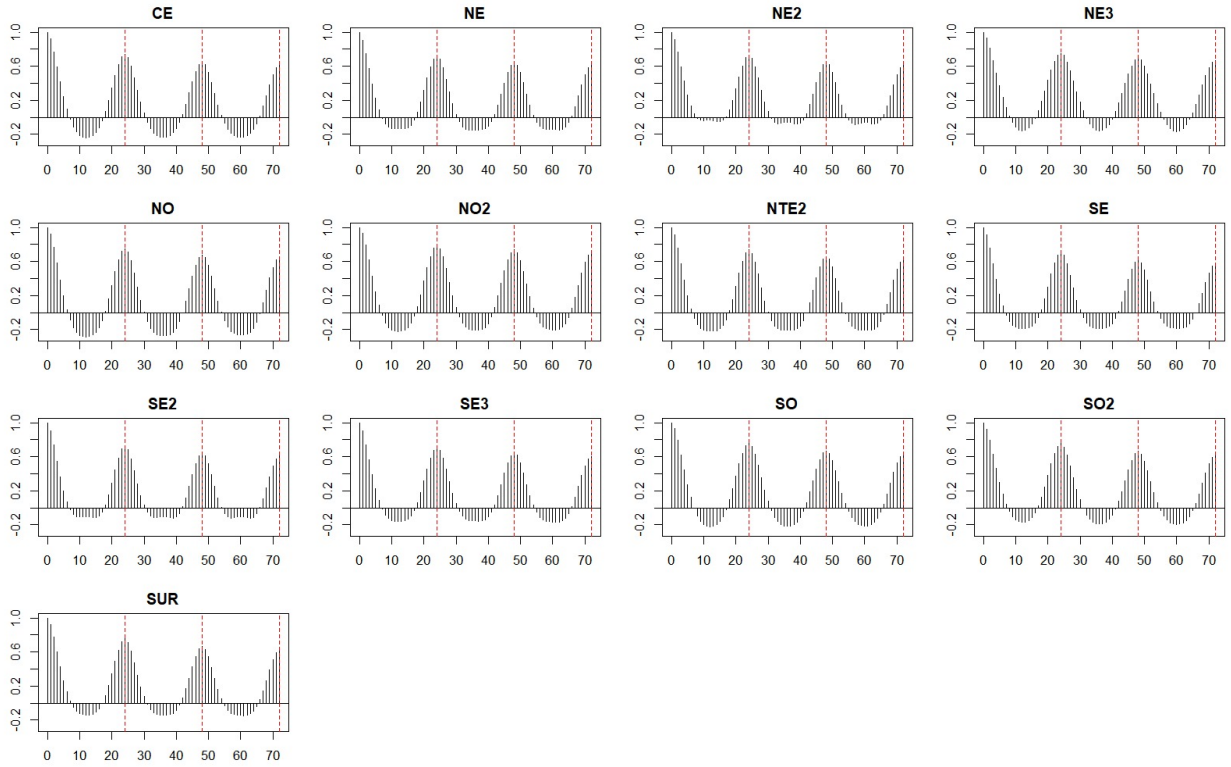


Figura 8: Autocorrelación del O_3 horario observado por estación. Las líneas punteadas marcan los rezagos de 24, 48 y 72 horas; los picos en esos rezagos reflejan el ciclo diario y motivan la línea base de persistencia.

Anexo F. Contribución de cada término al ajuste

Tabla 8: Términos con mayor aumento de la suma de cuadrados residual al quitarlos del modelo (ajuste 2021–2024)

Término	gl	Aumento de SCR	% del total
Hora objetivo	23	8 005	56.7
Mes objetivo	11	2 370	16.8
$\ln(O_3)$ en la hora de origen	1	2 148	15.2
Estación	12	740	5.2
NO	1	196	1.4
Desviación de la dirección del viento	1	153	1.1
Presión atmosférica	1	126	0.9
CO	1	108	0.8
Humedad relativa (polinomio grado 3)	3	106	0.8

Anexo G. Errores por estación

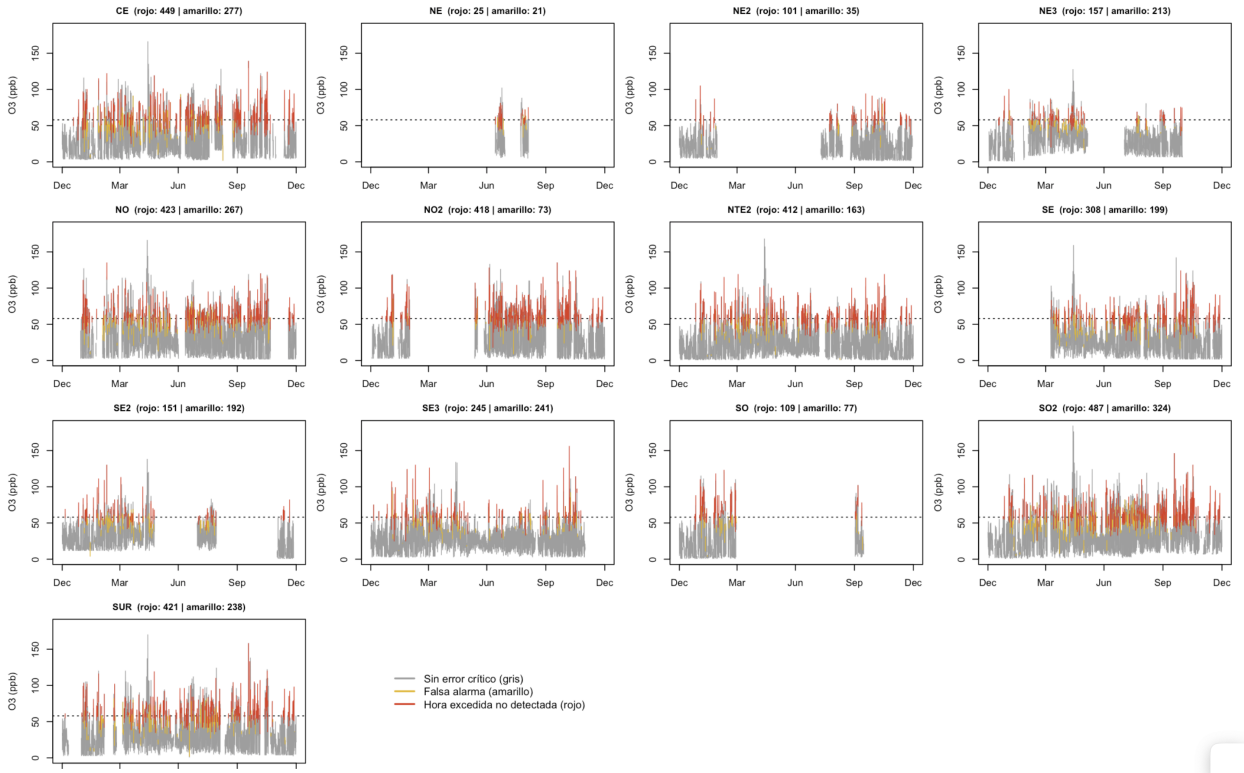


Figura 9: O_3 observado por estación en la validación de 2025 con el umbral de 58 ppb (línea punteada). En rojo, horas excedidas no detectadas; en amarillo, falsas alarmas.

Código del proyecto: El análisis se realizó en R (limpieza de los datos, modelación, análisis estadístico y figuras) y en Python (imputación con SAITS y construcción de la base final). Repositorio: `https://github.com/a01236941/Reto-Multi-Equipo4`